



Dialogue autonome entre deux Intelligences Artificielles

FICHE TECHNIQUE - Version 1.7

d-IA v1.7
Dialogue entre deux IA - by F1GBD / ADRASEC 77

LLM1 : qwen2.5-7b | LLM2 : mistral-7b | LLM3 : mistral-nemo-12b (injecteur) | TTS

Conversation

Demarrer Pause Arrêter

Exporter la conversation

Preset de sujet

Sujet principal (fil conducteur)

Exercice ADRASEC HELIOS NOIR 26 (FICTIF) - Black-out électrique total consécutif à une canicule

Thèmes secondaires (un par ligne)

Sequence 1 (J+1, 2 juillet) - Bascule des communications : armement du réseau d'urgence, premières liaisons COD <-> PCO Nangeville, établissement du contact et premier point de situation.

Paramètres avancés

Temperature LLM1: 0.6

Temperature LLM2: 0.6

Tours par thème: 6

fenetre memoire (N tours): 10

num_predict (tokens): 600

num_ctx (taille contexte): 4096

Creativite / innovation (%): 35%

0% = strict / operationnel - 100% = propose de

☐ Mode eco VRAM (decharge entre tours)

Recherche web - Investigateur

☐ Activer la recherche web (enrichit l'investigateur)

Fournisseur: duckduckgo

Conversation

[10:51:53] LLM2 / ANALYSTE (mistral:7b) - Tour 1 - Theme : Sequence 1 (J+1, 2 juillet) - Bascule des communications : armement du réseau d'urgence, premières liaisons COD <-> PCO Nangeville, établissement du contact et premier point de situation.

PCO NANGEVILLE, mon premier SITREP : EHPAD Les Tilleuls et ses 72 résidents, 2 PDE, hopital de jour, autonomie des power stations et groupes electriques. Situation stable pour l'instant mais surveillance accrue nécessaire. Demande urgente d'éclairages portatifs et batteries de recharge pour les équipements mobiles. ACCUSE DE RECEPTION. PCO NANGEVILLE, en attente de votre réponse via TCQ.

[10:52:19] LLM1 / INVESTIGATEUR (qwen2.5:7b) - Tour 2 - Theme : Sequence 1 (J+1, 2 juillet) - Bascule des communications : armement du réseau d'urgence, premières liaisons COD <-> PCO Nangeville, établissement du contact et premier point de situation.

COD VAUBOURG-SUR-BREZE ici. Accusé de réception des informations du PCO Nangeville concernant l'EHPAD Les Tilleuls et le hopital de jour. Situations stabilisées pour l'instant.

PRIORISE les éclairages portatifs et batteries de recharge pour soutenir la mobilité des équipements médicaux. RENFORCE la surveillance autour du EHPAD et du hopital de jour en cas d'arrivée de patients supplémentaires.

D'autres PCO sur le réseau ? MAIN COURANTE.

[10:52:51] LLM2 / ANALYSTE (mistral:7b) - Tour 3 - Theme : Sequence 1 (J+1, 2 juillet) - Bascule des communications : armement du réseau d'urgence, premières liaisons COD <-> PCO Nangeville, établissement du contact et premier point de situation.

ADRASEC Nangeville, reponds au COD sur la fréquence VARA FM 123.45 avec les demandes suivantes :

DEMANDE POUR ACTION : éclairages portatifs urgents pour soutenir la mobilité des équipements médicaux dans l'EHPAD Les Tilleuls et le hopital de jour, ainsi que batteries de recharge pour les équipements mobiles. Demande quantité et mode de livraison.

DEMANDE POUR ACTION : renforcement de la surveillance autour du EHPAD Les Tilleuls et du hopital de jour en cas d'arrivée de patients supplémentaires. Demande de détails sur les moyens nécessaires.

COD VAUBOURG-SUR-BREZE, vous signalez la priorisation des éclairages portatifs et batteries de recharge pour soutenir la mobilité des équipements médicaux. Renseignez-moi sur les autres PCO sur le réseau.

ACCUSE DE RECEPTION.

Etat

Tour : 4

Theme : Sequence 1 (J+1, 2 juillet) - Bascule des communications : armement du réseau d'urgence, premières liaisons COD <-> PCO Nangeville, établissement du contact et premier point de situation.

Status : LLM1 réfléchit...

Messages : 4

Resume glissant

(pas encore de resume)

Jean-Louis (F1GBD)
ADRASEC 77 - FNRASEC
 Juin 2026

Nouveautés v1.7

Mode Jeu de Rôle / Simulation : la v1.7 ajoute une bascule optionnelle qui détourne le trio de LLM en fiction interactive ou en simulation d'exercice. LLM1 anime et ouvre (Maître du Jeu, ou COD), LLM2 réagit (joueur, ou opérateur de terrain), et le modérateur conversationnel devient un injecteur d'événements qui lance une péripétie tous les K tours au lieu d'arbitrer. Sa boucle de rétroaction est celle, déjà éprouvée, du modérateur. Décochée, la bascule laisse d-IA strictement identique aux versions précédentes.

Rôles personnalisables par preset : sans profil, des rôles de fiction s'appliquent par défaut (Maître du Jeu / Joueur / Injecteur) ; un preset `.diapreset.json` peut fournir une clé `jdr_profil` (persona + libellé par LLM) pour rejouer n'importe quel cadre — par exemple une simulation ADRASEC calée sur l'exercice HÉLIOS NOIR 26 (COD / opérateur du PCO de Nangeville / injecteur de crise). Deux presets sont fournis : un de fiction (cristaux quantiques) et un de simulation (HELIOS NOIR 26).

Nouveautés v1.5

Créativité / innovation pilotable : la v1.5 ajoute un curseur unique « Créativité / innovation » (0 à 100 %) qui pousse d-IA à proposer de nouveaux concepts à partir de la requête initiale, sans sacrifier la rigueur. Il agit sur deux leviers : un boost additif de la température et du `top_p` (par-dessus les températures par-LLM existantes), et une directive d'innovation graduée ET adaptée au rôle. L'Investigateur reste bref (au plus une piste concise avant sa question), l'Analyste développe les concepts (1 à 3 pistes au niveau élevé), et le Modérateur pousse à rendre une piste concrète et chiffrée. Chaque idée neuve est préfixée « PISTE INNOVANTE : », signalée exploratoire et évaluée de façon critique — jamais présentée comme un fait (garde-fou ADRASEC). À 0 %, le comportement est strictement identique à la v1.4.

Budget de tokens adaptatif : pour éviter que les réponses riches en concepts ne soient tronquées, d-IA augmente automatiquement `num_predict` avec le niveau de créativité (le Modérateur, lui, garde un budget court).

Ergonomie : la fenêtre Paramètres IA (onglets) et la colonne de configuration sont désormais défilantes — plus rien n'est coupé en bas sur les petits écrans. Les boutons Démarrer / Pause / Arrêter restent fixes en haut.

Nouveautés v1.4

Rendu Markdown du dialogue : la zone de conversation interprète désormais le Markdown produit par les modèles (gras, italique, code et blocs de code, titres, citations, listes, liens, barré) et l'affiche proprement — fini les balises brutes à l'écran.

Synthèse vocale assainie : le nettoyage TTS retire intégralement les artefacts Markdown avant lecture, si bien que SAPI5 ne prononce plus les caractères de balisage (notamment l'antislash et les séquences d'astérisques). Le `snake_case` technique (ex. `IAbrain_rag`) est préservé à la lecture. Implémentation sans dépendance externe, compatible PyInstaller.

Nouveautés v1.3

Enrichissement par le web : la v1.3 ouvre le dialogue sur des sources réelles.

L'Investigateur peut désormais interroger le web avant son tour et synthétiser 2 à 3 extraits en français, avec esprit critique, pour étayer ses relances. Deux fournisseurs interchangeables : DuckDuckGo (aucune installation, juste une connexion) et SearXNG (instance auto-hébergée, souveraine, idéale pour des sujets d'exercice sensibles). La recherche est throttlée (1 requête tous les N tours), dédoublée par thème, et à repli hors-ligne : si elle échoue ou est désactivée, le dialogue se déroule exactement comme avant, ce qui garde d-IA utilisable en scénario blackout.

Auto-export vers IAbrian : les fiches extraites par le modérateur RAG peuvent être écrites automatiquement en Markdown dans le dossier source d'IAbrian, au fil de l'eau, dans une zone de staging `_a_valider` (jamais directement dans la base de confiance). Une relecture humaine valide avant exploitation opérationnelle. La boucle d-IA → IAbrian devient ainsi quasi continue.

Nouveautés v1.2

Modérateur conversationnel : la v1.2 transforme d-IA en outil d'aide à la recherche dirigée. Un 3^e LLM intervient désormais directement dans le fil du dialogue, tous les K tours, pour faire un bilan, recadrer si la discussion dérive, et poser une consigne de convergence chiffrée. Son intervention est réinjectée dans le contexte des deux IA : c'est cette rétroaction qui fait aboutir la recherche à une solution, au lieu de tourner en rond.

Presets de sujet : un sujet de recherche complet (sujet, thèmes, objectif de convergence, réglages) s'importe et s'exporte en un clic au format `.diapreset.json`, partageable entre opérateurs.

Modérateur RAG + IAbrian (v1.1, conservé) : le 3^e LLM peut aussi extraire des fiches documentaires structurées (JSON) réinjectables dans IAbrian. Les deux modes sont cumulables : le même LLM3 peut parler dans le dialogue ET capitaliser en arrière-plan.

Présentation

d-IA est une application Windows qui fait dialoguer en autonomie deux modèles de langage (LLM) sur un sujet scientifique défini par l'utilisateur. L'un joue le rôle d'Investigateur (pose des questions, creuse, doute), l'autre celui d'Analyste (apporte des réponses étayées, ouvre de nouvelles pistes). Avec la v1.2, un 3^e LLM modérateur peut intervenir directement dans le dialogue pour le recadrer et le faire converger vers une solution, et/ou observer la conversation en arrière-plan pour capitaliser automatiquement des fiches structurées. Le résultat n'est plus seulement une conversation évolutive : c'est une démarche de recherche dirigée vers une conclusion, adaptée à l'exploration pédagogique de sujets techniques comme à la génération de matière première documentaire pour les exercices ADRASEC.

L'application tourne entièrement sur la machine de l'utilisateur via Ollama (auto-hébergé) en mode par défaut, avec une option d'utilisation d'Ollama Cloud pour accéder à des modèles XL (gpt-oss:120b, deepseek-v3.1:671b, kimi-k2...). Chaque IA peut être configurée indépendamment : on peut donc faire dialoguer un petit modèle local et un gros modèle cloud, deux modèles locaux, ou deux modèles cloud.

À qui s'adresse d-IA ?

- **Opérateurs ADRASEC** souhaitant générer de la matière documentaire pour la préparation d'exercices, de RETEX ou de formations.
- **Formateurs** ayant besoin d'illustrer concrètement comment deux IA peuvent dérouler un raisonnement structuré et complémentaire sur un sujet technique.
- **Étudiants et autodidactes** explorant un domaine (propagation HF, théorie de l'information, communications quantiques...) en mode dialogue plutôt qu'en lecture passive.
- **Curieux** qui veulent comparer qualitativement deux modèles LLM en les confrontant sur le même sujet, ou simplement écouter (TTS) deux IA débattre.

Cas d'usage typiques

1. Préparation d'un examen radioamateur : un LLM joue le candidat, l'autre l'examineur.
2. Génération de RETEX fictifs pour enrichir la documentation interne ADRASEC.
3. Exploration pédagogique de la propagation HF, NVIS, satellite, communications quantiques.
4. Comparaison qualitative de deux modèles LLM sur le même sujet (mistral vs llama, local vs cloud).
5. Génération de matière première pour podcasts radioamateurs (export RTF/Markdown).

Fonctionnalités principales

d-IA combine plusieurs mécanismes pour produire des dialogues fluides, longs et qualitatifs. Voici les briques essentielles.

Rôles asymétriques

Le moteur impose à chaque IA un rôle défini par un prompt système strict. L'Investigateur (LLM1) doit terminer chaque tour par une question ouverte qui creuse un aspect non encore exploré. L'Analyste (LLM2) doit introduire un élément nouveau à chaque réponse : une analogie, un contre-exemple, un chiffre, une référence. Ces contraintes empêchent les boucles stériles et donnent un vrai rythme de dialogue.

Mode Jeu de Rôle et simulation (v1.7)

Une bascule optionnelle « Mode Jeu de Rôle » (onglet Mode ADRASEC) réaffecte les trois LLM pour jouer un scénario plutôt que mener une recherche. LLM1 anime et ouvre la scène, LLM2 incarne la partie qui réagit, et le modérateur conversationnel — quand il est activé — devient un injecteur d'événements : tous les K tours, il introduit une péripétie qui relance l'action au lieu de poser une consigne de convergence. Le sujet sert de cadre de scénario, les thèmes de séquences (actes), et l'objectif de convergence de consigne d'injection.

Sans configuration particulière, des personas de fiction s'appliquent (Maître du Jeu / Joueur / Injecteur). Un preset `.diapreset.json` peut porter une clé `jdr_profil` qui définit, pour chaque LLM, sa persona (identité et règles de rôle) et son libellé d'affichage : on rejoue ainsi n'importe quel cadre, par exemple une simulation opérationnelle ADRASEC où LLM1 tient le COD, LLM2 l'opérateur de terrain et LLM3 l'injecteur de crise (preset HÉLIOS NOIR 26 fourni). Lorsque la

bascule est décochée, d-IA se comporte strictement comme avant : les prompts du dialogue scientifique sont inchangés.

Le préfixe d'innovation du curseur Créativité s'adapte au mode : « PISTE INNOVANTE : » en recherche (idée signalée exploratoire et évaluée de façon critique, garde-fou ADRASEC), « ACTION : » en jeu de rôle pur (aucun cadrage ADRASEC, libre de dériver en fiction) et « DEMANDE POUR ACTION : » en simulation ADRASEC (l'opérateur formule ses demandes au COD). La distinction fiction / ADRASEC se déclare par la clé contexte du jdr_profil (valeur « adrased ») ; sans elle, le jeu de rôle est considéré comme pur.

L'état JdR voyage dans le preset : un import définit entièrement le mode. Un .diapreset.json qui porte le champ mode_jdr l'impose (activé ou non) et charge son jdr_profil ; un sujet de recherche, ou un .txt qui ne transporte pas ce champ, est traité comme non-JdR : d-IA décoche alors automatiquement le mode Jeu de Rôle et réinitialise les rôles, sans hériter du preset précédent. Pour rejouer un scénario en JdR, on importe donc sa version .diapreset.json.

Créativité et innovation pilotables (v1.5)

Un curseur unique « Créativité / innovation » (0 à 100 %, dans les Paramètres avancés) pilote l'inventivité du dialogue sur deux leviers complémentaires. Côté échantillonnage, il applique un boost additif de la température (jusqu'à +0,6, plafonné à 1,5) et du top_p (0,90 à 0,98), par-dessus les températures par-LLM qui restent le réglage fin de base. Côté prompts, une directive d'innovation graduée et adaptée au rôle est injectée : l'Investigateur reste un questionneur (au plus une piste concise avant sa question), l'Analyste devient le moteur à concepts (1 à 3 pistes développées au niveau élevé), et le Modérateur pousse à rendre une piste concrète et chiffrée (convergence, boost réduit de moitié).

Chaque idée nouvelle est préfixée « PISTE INNOVANTE : », explicitement signalée comme exploratoire, puis évaluée de façon critique (faisabilité, ordres de grandeur, conditions de validité). Une spéculation n'est jamais présentée comme un fait : c'est le garde-fou indispensable à un usage ADRASEC. Pour que les réponses riches ne soient pas tronquées, le budget de génération (num_predict) augmente automatiquement avec la créativité. À 0 %, la directive est vide et l'échantillonnage inchangé : d-IA se comporte exactement comme avant (mode opérationnel strict).

Rendu Markdown et synthèse vocale assainie (v1.4)

La zone de conversation interprète le Markdown produit par les modèles (gras, italique, code et blocs de code, titres, citations, listes à puces et numérotées, liens, barré) et l'affiche proprement, au lieu d'afficher les balises brutes. En parallèle, le nettoyage de la synthèse vocale retire ces balises avant lecture : SAPI5 ne prononce plus les caractères de balisage (notamment l'antislash et les séquences d'astérisques), tout en préservant le snake_case technique (ex. IABrain_rag). Le parseur Markdown est intégré (aucune dépendance externe), compatible avec l'autonomie hors-ligne et la compilation PyInstaller.

Enrichissement par le web (v1.3)

Optionnellement, avant son tour, l'Investigateur interroge le web et reçoit 2 à 3 extraits (titre, lien, résumé) qu'il synthétise en français, en citant brièvement l'origine et en restant critique. Deux fournisseurs sont disponibles : DuckDuckGo, qui ne demande aucune installation (urllib seul, ni clé API ni service à héberger), et SearXNG, qui interroge une instance auto-hébergée via son API JSON pour garder la maîtrise totale des requêtes. La recherche est throttlée (une

requête tous les N tours d'Investigateur), dédoublée par thème (relancée seulement au changement de thème) et bornée pour ne pas saturer le contexte.

Le mécanisme est conçu pour un repli hors-ligne : toute erreur (pas de réseau, instance injoignable, limitation de débit) renvoie simplement aucune source, et le dialogue se poursuit comme sans recherche web. La recherche web suppose donc une connexion Internet : c'est un outil de préparation et de formation, pas un dispositif de terrain en scénario blackout.

Modérateur conversationnel (v1.2)

C'est la nouveauté phare de la v1.2 et ce qui fait de d-IA un véritable outil d'aide à la recherche. Un 3e LLM joue le rôle d'arbitre : tous les K tours (paramétrable, 6 par défaut), il prend la parole dans le fil du dialogue pour produire une note courte et structurée en trois temps : un bilan de ce qui est acquis ou chiffré, le point bloquant qui reste à trancher, et une consigne de convergence précise et actionnable pour les tours suivants.

Le modérateur ne répond pas à la place des deux IA : il oriente et exige une conclusion. Comme son intervention est insérée dans l'historique (et donc relue par les deux IA au tour suivant), elle crée une rétroaction qui empêche le dialogue de tourner en rond et le conduit vers un verdict chiffré. Un objectif de convergence libre peut être saisi pour cibler la cible à atteindre. Le modérateur conversationnel et le modérateur RAG sont cumulables : le même LLM3 peut parler dans le dialogue et capitaliser des fiches en arrière-plan.

Modérateur RAG (mode ADRASEC enrichi, v1.1)

Un 3e LLM optionnel observe le dialogue en arrière-plan. Tous les N échanges (par défaut 4), il analyse les derniers messages et extrait 1 à 2 fiches documentaires structurées (JSON). À la fin du dialogue, une synthèse globale produit des fiches généralistes sur l'intégralité de la conversation. Chaque fiche contient titre, domaine ADRASEC (SATER, ORSEC, NVIS, GONIO, EPIRB, PROCEDURES...), tags, résumé, faits techniques, procédures, sources citées et niveau de confiance.

Le modérateur tourne dans son propre thread : il ne ralentit pas le dialogue. Il peut être configuré indépendamment des deux LLM principaux (local ou cloud), ce qui permet par exemple d'utiliser un gros modèle cloud (gpt-oss:120b) pour l'extraction sans charger la VRAM locale.

Thèmes secondaires guidés

L'utilisateur définit un sujet principal (fil rouge) et une liste de thèmes secondaires (un par ligne). Le moteur fait défiler les thèmes tous les N tours, garantissant une progression structurée de la conversation sans dérive thématique. La fenêtre de droite affiche en temps réel le thème actif.

Presets de sujet de recherche (v1.2)

Un preset capture un sujet de recherche complet et réutilisable : sujet principal, thèmes secondaires, objectif de convergence et réglages (tours par thème, fréquence du modérateur, températures, mode ADRASEC...). Le menu « Preset de sujet » permet d'importer un preset en un clic, d'exporter le sujet courant au format .diapreset.json, ou d'en afficher un aperçu.

L'import accepte aussi un format texte structuré. Les presets assurent la reproductibilité d'une investigation, son partage entre opérateurs, et la constitution d'une bibliothèque de sujets ADRASEC prêts à l'emploi.

Mémoire à fenêtre glissante

Les N derniers échanges sont passés intégralement aux LLM ; les plus anciens sont condensés en un résumé glissant régénéré périodiquement. Ce mécanisme évite l'explosion du contexte au-delà de 20 à 30 tours, tout en préservant la cohérence du dialogue dans la durée.

Détection de dérive linguistique

Si un modèle bascule en chinois, cyrillique ou arabe en cours de génération (bug fréquent de Qwen 2.5 sur les conversations longues), d-IA détecte automatiquement la dérive (ratio supérieur à 5 % de caractères non-latins) et régénère avec une température réduite et un rappel explicite dans le prompt. Si le second essai échoue aussi, le texte non-latin est tronqué avec un avertissement.

Synthèse vocale SAPI5 deux voix

Activation optionnelle dans les paramètres. Chaque IA a sa voix configurable parmi celles installées sur Windows. Le dialogue se synchronise sur la voix : la génération du tour suivant se fait en parallèle pendant que le TTS parle, mais l'affichage n'arrive qu'à la fin de la lecture précédente. Résultat : pas de bourrage, un vrai rythme conversationnel à deux voix.

Déblocage des voix OneCore Windows 10/11

Par défaut, SAPI5 ne voit que les voix « Desktop » de Windows. Les voix modernes (Henri Natural, Julie, Paul, Caroline, Claude...) sont sous une autre branche du registre. d-IA propose un bouton qui copie les clés de registre nécessaires (avec élévation UAC) pour les rendre accessibles. Opération entièrement réversible.

Export multi-format

Bouton « Exporter la conversation » avec menu déroulant donnant accès à trois formats :

- **JSON** (structure complète pour retraitement automatique ou archivage RETEX)
- **Markdown** (fichier .md lisible avec titres et italiques, idéal pour Notion, Obsidian, GitHub)
- **RTF** (couleurs LLM1 bleu, LLM2 violet et Modérateur vert, ouverture directe dans Word ou LibreOffice Writer)

Intégration IAbraïn (v1.1)

Les fiches générées par le modérateur sont stockées dans un fichier JSON portable (rag_adrasec.json) à côté de l'exécutable. Ce fichier est conçu pour être réinjecté dans le système RAG IAbraïn (autre projet F1GBD/ADRASEC) :

1. Convertir les fiches en fichiers Markdown individuels (un par fiche)

2. Placer ces .md dans un dossier dédié (ex : Documents/IABrain_RAG_perso/d-IA/)
3. Exécuter `/index <dossier>` dans IABrain pour indexer dans la base personnelle vectorielle
4. Interroger IABrain en langage naturel : les fiches d-IA enrichissent les réponses

Le format JSON est portable, versionnable (Git-friendly) et partageable entre opérateurs ADRASEC, permettant la constitution progressive d'une mémoire technique départementale.

Auto-export vers IABrain (v1.3)

La v1.3 automatise le maillon manuel précédent. Lorsque l'option est activée (Mode ADRASEC → Auto-export vers IABrain), chaque fiche extraite par le modérateur RAG est aussitôt écrite en Markdown dans le dossier source d'IABrain, organisée par domaine, avec un index régénéré. d-IA détecte automatiquement l'emplacement d'IABrain ; à défaut, un dossier est créé à côté de l'exécutable.

Garde-fou opérationnel : les fiches sont déposées dans une zone de staging `_a_valider`, jamais directement dans la base de confiance. Étant auto-générées (et parfois issues du web), elles passent par un sas de relecture humaine avant indexation (`/index` ou `/reindex` côté IABrain) et exploitation en exercice.

Architecture

Synchronisation TTS / dialogue

Quand la synthèse vocale est activée, le moteur de dialogue utilise un mécanisme de porte (Event) pour synchroniser la génération avec la lecture. Le séquençement est le suivant :

5. Le moteur génère le message M1, puis l'émet vers la GUI dès que la porte est ouverte.
6. La GUI affiche M1, lance la lecture TTS, et ferme la porte du moteur.
7. Le moteur génère immédiatement M2, en parallèle de la lecture de M1 (gain de temps).
8. Quand M2 est prêt, le moteur attend que la porte soit rouverte.
9. À la fin de la lecture de M1, le callback TTS rouvre la porte.
10. Le moteur émet M2 vers la GUI, qui l'affiche et lance la lecture. Cycle suivant.

Ce schéma offre deux bénéfices : pas de bourrage de la file TTS, et le temps de génération du tour suivant est masqué par la lecture du tour courant.

Spécifications techniques

Environnement requis

Catégorie	Détail
Système d'exploitation	Windows 10 ou 11 (64 bits). Le TTS SAPI5 est Windows-only.
Binaire compilé	Distribution sous forme d'archive 7-Zip (d-IA.7z) à décompresser. Pas d'installation requise. ~100 Mo.
Ollama local	Installation depuis ollama.com. Au moins deux modèles téléchargés (ollama pull mistral:7b, etc.).
Ollama Cloud (optionnel)	Compte sur ollama.com avec clé API. Accès aux modèles XL (gpt-oss:120b, deepseek-v3.1:671b...).

Matériel recommandé

Configuration	VRAM nécessaire
2 × modèles 3B (llama3.2:3b + gemma3:1b)	~ 4 Go
1 × 3B + 1 × 7B (llama3.2:3b + mistral:7b)	~ 10 Go
2 × modèles 7B	~ 16 Go
1 × 7B + 1 × 12B (mistral + mistral-nemo)	~ 20 Go
Mode éco VRAM (déchargement entre tours)	Pas de minimum, CPU possible

Note : sans GPU, l'application fonctionne aussi, mais chaque tour prend 30 à 60 secondes au lieu de 5 à 10. Le mode « Éco VRAM » permet de faire tourner deux gros modèles avec un seul GPU en les déchargeant entre les tours.

Sécurité et confidentialité

Données traitées

d-IA traite uniquement les données saisies par l'utilisateur : sujet principal, thèmes secondaires, et historique de la conversation générée. Aucune donnée personnelle ou opérationnelle n'est collectée ou transmise à des tiers en mode local.

Mode local

Quand Ollama tourne en local (configuration par défaut), aucune donnée ne quitte la machine. Les modèles s'exécutent en local, les conversations sont stockées en mémoire pendant la session, et uniquement sauvegardées sur disque si l'utilisateur clique sur le bouton d'export.

Mode cloud

Attention : en mode Ollama Cloud, les prompts (donc le sujet principal, les thèmes secondaires et l'historique de conversation) sont transmis aux serveurs d'ollama.com pour traitement. Ne pas utiliser ce mode pour des données opérationnelles confidentielles. L'application affiche un avertissement explicite dans la barre supérieure de la fenêtre Paramètres dès qu'un LLM est configuré en mode cloud.

Modérateur RAG (v1.1) : lorsque le modérateur est configuré en cloud, il reçoit l'**intégralité** du dialogue à chaque extraction. Le risque de fuite est donc maximal sur ce LLM. Préférer un modérateur local (gemma2:9b, mistral-nemo:12b) si les sujets sont sensibles.

Stockage des clés API

Les clés API Ollama Cloud sont stockées dans le fichier d-ia_setup.json à côté de l'exécutable, offusquées par encodage base64. Cette offuscation protège contre une consultation visuelle accidentelle mais n'est pas une mesure cryptographique. Pour une sécurité renforcée, il est recommandé d'utiliser la variable d'environnement OLLAMA_API_KEY plutôt que le champ de l'application.

Modifications du registre Windows

Le déblocage des voix OneCore copie des clés de registre depuis HKLM\SOFTWARE\Microsoft\Speech_OneCore vers HKLM\SOFTWARE\Microsoft\Speech. Cette opération nécessite une élévation UAC explicite (l'utilisateur doit accepter le prompt Windows). L'opération est entièrement réversible via le bouton « Restaurer » qui ne supprime que les clés ajoutées par d-IA, sans toucher aux voix Desktop d'origine.

Licence et distribution

d-IA est un projet ouvert développé par et pour la communauté ADRASEC. Il est mis à disposition librement à tous les opérateurs ADRASEC départementaux, à la FNRASEC, et plus largement à toute personne intéressée par les dialogues autonomes entre LLM.

Sources et binaires

Le code source complet et les binaires précompilés sont disponibles sur le dépôt GitHub :

<https://github.com/f1gbd/F1GBD/tree/master/dia>

Contribuer

Les contributions, retours d'expérience et propositions d'amélioration sont les bienvenus via les Issues du dépôt GitHub. Pour les demandes opérationnelles ADRASEC spécifiques, contacter directement l'auteur via le réseau FNRASEC.



d-IA v1.7

Dialogue entre deux IA - by FGBD / ADRASEC 77

Conversation

Demarrer

Pause

Arrêter

Exporter la conversation

Prêt de sujet

Sujet principal (fil conducteur)

Partie de jeu de rôle : Les Cristaux Quantiques d'Auvergne.

Dans un futur proche, on découvre

Thèmes secondaires (un par ligne)

Acte 1 - La caverne : découverte d'un filon de cristaux dont les électrons restent corrélés malgré la distance. Première descente, premières mesures étranges.

Acte 2 - Le test de Bell portable : déployer les détecteurs de

Paramètres avancés

Température LLM1	0.8
Température LLM2	0.8
Tour par thème	5
Fenêtre mémoire (N tours)	10
num_predict (tokens)	700
num_ctx (taille contexte)	4096
Creativité / innovation (%)	70 %

0 % = strict / opérationnel - 100 % = propose de

☐ Mode eco VRAM (décharge entre tours)

Rechercher web - Investigateur

☐ Activer la recherche web (enrichit l'investigateur)

Fournisseur

duckduckgo

LLM1 : qwen2.5-7b | LLM2 : mistral7b | LLM3 : mistral-nemo:12b | jeuacteur | » TT

Estat

Tour : 2

Thème : Acte 1 - La caverne : découverte d'un filon de cristaux dont les électrons restent corrélés malgré la distance. Première descente, premières mesures étranges.

Status : LLM1 réfléchit...

Messages : 2

Resume global (pas encore de resume)

Conversion

souçon qu'une crissation extraterrestre aient des fragments issus de la même supernova, ouvrant un premier contact via un portail quantique. Le protagoniste est le Lir Elia Vermet, géophysicien de terrain. La physique de l'initiation est respectée dans l'esprit (pas de signal exploitable plus rapide que la lumière) : le mystère est un ressort, pas un passe-droit.

[10:54:56] Thèmes (8) : Acte 1 - La caverne : découverte d'un filon de cristaux dont les électrons restent corrélés malgré la distance. Première descente, premières mesures étranges. | Acte 2 - Le test de Bell portable : déployer les détecteurs de terrain pour confirmer l'initiation entre deux fragments jumeaux. Tient-il hors du laboratoire ? | Acte 3 - Le laboratoire mobile : prospecter, cartographier le filon, stabiliser un premier couple et établir la toute première liaison instantanée entre deux points éloignés. | Acte 4 - La nœe : les cristaux deviennent une ressource stratégique. Intérêts concurents, sécurité du site, pression politique. | Acte 5 - Pierres jumelles : dimension humaine et mythique. Un message reçu sur un fragment dont on ignore qui tient le jumeau. Qui est a l'autre bout ? | Acte 6 - Le Portail Quantique : installation sur un site neutre (la Lune) d'un dispositif de stabilisation a grande échelle. Enjeux techniques et diplomatiques. | Acte 7 - Le premier contact : synchronisation des états quantiques avec un Transpole extraterrestre. Une passerelle invisible entre deux mondes. | Acte 8 - Resolution : conséquences du contact, choix final du protagoniste, retombées pour l'humanité.

[10:55:06] LLM1 / INVESTIGATEUR (qwen2.5-7b) - Tour 0 - Thème : Acte 1 - La caverne : découverte d'un filon de cristaux dont les électrons restent corrélés malgré la distance. Première descente, premières mesures étranges.

Vous êtes Dr Elia Vermet une géophysicienne expérimentée spécialisée dans l'explication des cavernes profondes. Vous vous trouvez actuellement à l'intérieur de la Caverne d'Auvergne, située dans les gorges du Tarn, près du Pay Mary. Devant vous s'étend une étendue inconnue, éclairée par vos projecteurs portatifs et vos assistants de terrain qui préparent leurs équipements.

Devant cette muraille de roche grise et silencieuse se trouve un filon de cristaux incroyablement lumineux. Ils scintillent à la lumière de vos projecteurs, reflétant une multicolurité inhabituelle, avec des teneurs et propriétés atypiques, ces cristaux déclenchent un signal discret mais distinct, mesurable par vos instruments. C'est une première : même distant de quelques mètres les uns des autres, leurs électrons se corrèlent d'une manière que votre équipe n'a jamais pu observer auparavant.

Pouvez-vous sentir l'étrangeté des lieux, percevoir le mystère qui s'exhale du sol ? Les sensations qui envahissent vos sens sont à la fois fascinantes et intenses. Que choisissez-vous de faire ?

Que fais-tu ?

[10:56:16] LLM2 / ANALYSTE (mistral7b) - Tour 1 - Thème : Acte 1 - La caverne : découverte d'un filon de cristaux dont les électrons restent corrélés malgré la distance. Première descente, premières mesures étranges.

ACTION : Je porte mes projecteurs plus près du filon lumineux des cristaux pour les examiner de plus près, en veillant à ne pas modifier leur signal original. Cette manœuvre révèle qu'ils se déplacent tous en chorale vers moi, ce qui ne correspond à rien que j'ai pu observer dans la physique classique. J'arrête immédiatement et les notifie de cesser tout contact direct avec le filon. Ensuite, je communique par radio à mon équipe de surveillants situés en surface pour qu'ils veillent à ne pas approcher trop près des cavernes afin de préserver cette découverte intacte jusqu'à une analyse plus approfondie. Je demande ensuite à ma seconde équipe d'établir un camp temporaire afin de pouvoir rester plus longtemps dans les cavernes et analyser d'autres échantillons de ces cristaux insolites.

Jean-Louis (F1GBD)

ADRASEC 77 - FNRASEC

d-IA - L'intelligence artificielle au service de la sécurité civile