



FICHE TECHNIQUE - Version 1.1



Mai 2026

Nouveautés v1.1

Modérateur RAG : la v1.1 ajoute un 3^e LLM qui observe le dialogue en arrière-plan et extrait automatiquement des fiches documentaires structurées (JSON). Chaque dialogue devient ainsi une matière directement réutilisable pour exercices, RETEX, base RAG.

Intégration IAbraïn : les fiches produites peuvent être réinjectées directement dans le système RAG IAbraïn pour interrogation en langage naturel. d-IA devient le générateur de matière première, IAbraïn la mémoire interrogeable.

Présentation

d-IA est une application Windows qui fait dialoguer en autonomie deux modèles de langage (LLM) sur un sujet scientifique défini par l'utilisateur. L'un joue le rôle d'Investigateur (pose des questions, creuse, doute), l'autre celui d'Analyste (apporte des réponses étayées, ouvre de nouvelles pistes). Avec la v1.1, un 3^e LLM modérateur observe la conversation en arrière-plan et capitalise automatiquement les informations sous forme de fiches structurées. Le résultat est une conversation évolutive avec un fil conducteur, parfaitement adaptée à l'exploration pédagogique de sujets techniques ou à la génération de matière première documentaire pour les exercices ADRASEC.

L'application tourne entièrement sur la machine de l'utilisateur via Ollama (auto-hébergé) en mode par défaut, avec une option d'utilisation d'Ollama Cloud pour accéder à des modèles XL (gpt-oss:120b, deepseek-v3.1:671b, kimi-k2...). Chaque IA peut être configurée indépendamment : on peut donc faire dialoguer un petit modèle local et un gros modèle cloud, deux modèles locaux, ou deux modèles cloud.

À qui s'adresse d-IA ?

- **Opérateurs ADRASEC** souhaitant générer de la matière documentaire pour la préparation d'exercices, de RETEX ou de formations.
- **Formateurs** ayant besoin d'illustrer concrètement comment deux IA peuvent dérouler un raisonnement structuré et complémentaire sur un sujet technique.
- **Étudiants et autodidactes** explorant un domaine (propagation HF, théorie de l'information, communications quantiques...) en mode dialogue plutôt qu'en lecture passive.
- **Curieux** qui veulent comparer qualitativement deux modèles LLM en les confrontant sur le même sujet, ou simplement écouter (TTS) deux IA débattre.

Cas d'usage typiques

1. Préparation d'un examen radioamateur : un LLM joue le candidat, l'autre l'examineur.
2. Génération de RETEX fictifs pour enrichir la documentation interne ADRASEC.
3. Exploration pédagogique de la propagation HF, NVIS, satellite, communications quantiques.
4. Comparaison qualitative de deux modèles LLM sur le même sujet (mistral vs llama, local vs cloud).
5. Génération de matière première pour podcasts radioamateurs (export RTF/Markdown).

Fonctionnalités principales

d-IA combine plusieurs mécanismes pour produire des dialogues fluides, longs et qualitatifs. Voici les briques essentielles.

Rôles asymétriques

Le moteur impose à chaque IA un rôle défini par un prompt système strict. L'Investigateur (LLM1) doit terminer chaque tour par une question ouverte qui creuse un aspect non encore exploré. L'Analyste (LLM2) doit introduire un élément nouveau à chaque réponse : une analogie, un contre-exemple, un chiffre, une référence. Ces contraintes empêchent les boucles stériles et donnent un vrai rythme de dialogue.

Modérateur RAG (mode ADRASEC enrichi, v1.1)

Un 3e LLM optionnel observe le dialogue en arrière-plan. Tous les N échanges (par défaut 4), il analyse les derniers messages et extrait 1 à 2 fiches documentaires structurées (JSON). À la fin du dialogue, une synthèse globale produit des fiches généralistes sur l'intégralité de la conversation. Chaque fiche contient titre, domaine ADRASEC (SATER, ORSEC, NVIS, GONIO, EPIRB, PROCEDURES...), tags, résumé, faits techniques, procédures, sources citées et niveau de confiance.

Le modérateur tourne dans son propre thread : il ne ralentit pas le dialogue. Il peut être configuré indépendamment des deux LLM principaux (local ou cloud), ce qui permet par exemple d'utiliser un gros modèle cloud (gpt-oss:120b) pour l'extraction sans charger la VRAM locale.

Thèmes secondaires guidés

L'utilisateur définit un sujet principal (fil rouge) et une liste de thèmes secondaires (un par ligne). Le moteur fait défiler les thèmes tous les N tours, garantissant une progression structurée de la conversation sans dérive thématique. La fenêtre de droite affiche en temps réel le thème actif.

Mémoire à fenêtre glissante

Les N derniers échanges sont passés intégralement aux LLM ; les plus anciens sont condensés en un résumé glissant régénéré périodiquement. Ce mécanisme évite l'explosion du contexte au-delà de 20 à 30 tours, tout en préservant la cohérence du dialogue dans la durée.

Détection de dérive linguistique

Si un modèle bascule en chinois, cyrillique ou arabe en cours de génération (bug fréquent de Qwen 2.5 sur les conversations longues), d-IA détecte automatiquement la dérive (ratio supérieur à 5 % de caractères non-latins) et régénère avec une température réduite et un rappel explicite dans le prompt. Si le second essai échoue aussi, le texte non-latin est tronqué avec un avertissement.

Synthèse vocale SAPI5 deux voix

Activation optionnelle dans les paramètres. Chaque IA a sa voix configurable parmi celles installées sur Windows. Le dialogue se synchronise sur la voix : la génération du tour suivant se fait en parallèle pendant que le TTS parle, mais l'affichage n'arrive qu'à la fin de la lecture précédente. Résultat : pas de bourrage, un vrai rythme conversationnel à deux voix.

Débloquer des voix OneCore Windows 10/11

Par défaut, SAPI5 ne voit que les voix « Desktop » de Windows. Les voix modernes (Henri Natural, Julie, Paul, Caroline, Claude...) sont sous une autre branche du registre. d-IA propose un bouton qui copie les clés de registre nécessaires (avec élévation UAC) pour les rendre accessibles. Opération entièrement réversible.

Export multi-format

Bouton « Exporter la conversation » avec menu déroulant donnant accès à trois formats :

- **JSON** (structure complète pour retraitement automatique ou archivage RETEX)
- **Markdown** (fichier .md lisible avec titres et italiques, idéal pour Notion, Obsidian, GitHub)
- **RTF** (couleurs LLM1 bleu et LLM2 violet, ouverture directe dans Word ou LibreOffice Writer)

Intégration IAbrian (v1.1)

Les fiches générées par le modérateur sont stockées dans un fichier JSON portable (rag_adrasec.json) à côté de l'exécutable. Ce fichier est conçu pour être réinjecté dans le système RAG IAbrian (autre projet F1GBD/ADRASEC) :

1. Convertir les fiches en fichiers Markdown individuels (un par fiche)
2. Placer ces .md dans un dossier dédié (ex : Documents/IAbrian_RAG_perso/d-IA/)
3. Exécuter /index <dossier> dans IAbrian pour indexer dans la base personnelle vectorielle
4. Interroger IAbrian en langage naturel : les fiches d-IA enrichissent les réponses

Le format JSON est portable, versionnable (Git-friendly) et partageable entre opérateurs ADRASEC, permettant la constitution progressive d'une mémoire technique départementale.

Architecture

d-IA est une application Python 3.13 utilisant Tkinter pour l'interface graphique, et la librairie officielle Ollama pour le dialogue avec les modèles LLM. Le code suit une architecture en trois couches asynchrones.

Schéma des flux

Composant	Rôle
DialogueGUI	Interface Tkinter, gestion des événements utilisateur, affichage des messages, configuration des paramètres.
DialogueEngine	Thread principal du dialogue. Orchestration des tours, alternance Investigateur/Analyste, gestion des thèmes, mémoire glissante, détection de dérive.

Composant	Rôle
OllamaClient	Une instance par LLM (3 instances en mode v1.1). Encapsule les appels HTTP à Ollama local ou Ollama Cloud, avec authentification par clé API et gestion du keep-alive.
ModeratorEngine (v1.1)	Thread dédié à l'analyse RAG. Observe les messages au fil de l'eau, déclenche une extraction toutes les N tours via le LLM3, parse le JSON retourné (parser tolérant aux artefacts) et persiste les fiches dans rag_adrasec.json.
RAGStore (v1.1)	Persistance JSON atomique des fiches (écriture .tmp + os.replace). Anti-doublon par titre + date. Statistiques de la session et de la base globale.
TTSEngine	Thread dédié à la synthèse vocale. Utilise SAPI5 directement via win32com (et non pyttsx3) pour éviter les problèmes de singleton COM multi-thread. Synchronisation avec le moteur de dialogue via Event threading.
Event queue	File d'événements thread-safe entre DialogueEngine et DialogueGUI. La GUI poll la queue toutes les 100 ms pour rafraîchir l'affichage sans bloquer.

Synchronisation TTS / dialogue

Quand la synthèse vocale est activée, le moteur de dialogue utilise un mécanisme de porte (Event) pour synchroniser la génération avec la lecture. Le séquençement est le suivant :

5. Le moteur génère le message M1, puis l'émet vers la GUI dès que la porte est ouverte.
6. La GUI affiche M1, lance la lecture TTS, et ferme la porte du moteur.
7. Le moteur génère immédiatement M2, en parallèle de la lecture de M1 (gain de temps).
8. Quand M2 est prêt, le moteur attend que la porte soit rouverte.
9. À la fin de la lecture de M1, le callback TTS rouvre la porte.
10. Le moteur émet M2 vers la GUI, qui l'affiche et lance la lecture. Cycle suivant.

Ce schéma offre deux bénéfices : pas de bourrage de la file TTS, et le temps de génération du tour suivant est masqué par la lecture du tour courant.

Spécifications techniques

Environnement requis

Catégorie	Détail
Système d'exploitation	Windows 10 ou 11 (64 bits). Le TTS SAPI5 est Windows-only.
Binaire compilé	Distribution sous forme d'archive 7-Zip (d-IA.7z) à décompresser. Pas d'installation requise. ~100 Mo.
Ollama local	Installation depuis ollama.com. Au moins deux modèles téléchargés (ollama pull mistral:7b, etc.).
Ollama Cloud (optionnel)	Compte sur ollama.com avec clé API. Accès aux modèles XL (gpt-oss:120b, deepseek-v3.1:671b...).

Matériel recommandé

Configuration	VRAM nécessaire
2 × modèles 3B (llama3.2:3b + gemma3:1b)	~ 4 Go
1 × 3B + 1 × 7B (llama3.2:3b + mistral:7b)	~ 10 Go
2 × modèles 7B	~ 16 Go
1 × 7B + 1 × 12B (mistral + mistral-nemo)	~ 20 Go
Mode éco VRAM (déchargement entre tours)	Pas de minimum, CPU possible

Note : sans GPU, l'application fonctionne aussi, mais chaque tour prend 30 à 60 secondes au lieu de 5 à 10. Le mode « Éco VRAM » permet de faire tourner deux gros modèles avec un seul GPU en les déchargeant entre les tours.

Sécurité et confidentialité

Données traitées

d-IA traite uniquement les données saisies par l'utilisateur : sujet principal, thèmes secondaires, et historique de la conversation générée. Aucune donnée personnelle ou opérationnelle n'est collectée ou transmise à des tiers en mode local.

Mode local

Quand Ollama tourne en local (configuration par défaut), aucune donnée ne quitte la machine. Les modèles s'exécutent en local, les conversations sont stockées en mémoire pendant la session, et uniquement sauvegardées sur disque si l'utilisateur clique sur le bouton d'export.

Mode cloud

Attention : en mode Ollama Cloud, les prompts (donc le sujet principal, les thèmes secondaires et l'historique de conversation) sont transmis aux serveurs d'ollama.com pour traitement. Ne pas utiliser ce mode pour des données opérationnelles confidentielles. L'application affiche un avertissement explicite dans la barre supérieure de la fenêtre Paramètres dès qu'un LLM est configuré en mode cloud.

Modérateur RAG (v1.1) : lorsque le modérateur est configuré en cloud, il reçoit l'intégralité du dialogue à chaque extraction. Le risque de fuite est donc maximal sur ce LLM. Préférer un modérateur local (gemma2:9b, mistral-nemo:12b) si les sujets sont sensibles.

Stockage des clés API

Les clés API Ollama Cloud sont stockées dans le fichier d-ia_setup.json à côté de l'exécutable, offusquées par encodage base64. Cette offuscation protège contre une consultation visuelle accidentelle mais n'est pas une mesure cryptographique. Pour une sécurité renforcée, il est

recommandé d'utiliser la variable d'environnement OLLAMA_API_KEY plutôt que le champ de l'application.

Modifications du registre Windows

Le déblocage des voix OneCore copie des clés de registre depuis HKLM\SOFTWARE\Microsoft\Speech_OneCore vers HKLM\SOFTWARE\Microsoft\Speech. Cette opération nécessite une élévation UAC explicite (l'utilisateur doit accepter le prompt Windows). L'opération est entièrement réversible via le bouton « Restaurer » qui ne supprime que les clés ajoutées par d-IA, sans toucher aux voix Desktop d'origine.

Licence et distribution

d-IA est un projet ouvert développé par et pour la communauté ADRASEC. Il est mis à disposition librement à tous les opérateurs ADRASEC départementaux, à la FNRASEC, et plus largement à toute personne intéressée par les dialogues autonomes entre LLM.

Sources et binaires

Le code source complet et les binaires précompilés sont disponibles sur le dépôt GitHub :

<https://github.com/f1gbd/F1GBD/tree/master/dia>

Contribuer

Les contributions, retours d'expérience et propositions d'amélioration sont les bienvenus via les Issues du dépôt GitHub. Pour les demandes opérationnelles ADRASEC spécifiques, contacter directement l'auteur via le réseau FNRASEC.

Jean-Louis (F1GBD)

ADRASEC 77 - FNRASEC

d-IA - L'intelligence artificielle au service de la sécurité civile