

Installer & paramétrer Tesseract (OCR des documents scannés)

À faire une fois par poste. Nécessaire pour qu'IAbrain reconnaisse et indexe le texte des documents **scannés** (conventions signées, arrêtés, protocoles) — PDF image ou Word ne contenant que des images. Coche chaque case au fur et à mesure.

1. Télécharger

- ☐ Ouvrir la page officielle Windows : github.com/UB-Mannheim/tesseract/wiki
- ☐ Télécharger l'installateur **64 bits** : `tesseract-ocr-w64-setup-....exe`

2. Installer étape clé : la langue française

- ☐ Lancer l'installateur (**clic droit → Exécuter en tant qu'administrateur**).
- ☐ À l'écran « **Additional language data (download)** », déplier la liste et **COCHER « French »** (données fra) — **indispensable**, sinon l'OCR échoue avec « Failed loading language 'fra' ».
- ☐ Si proposé, cocher aussi « **Add Tesseract to system PATH** ».
- ☐ Laisser le dossier par défaut : `C:\Program Files\Tesseract-OCR\`.
- ☐ Terminer l'installation.

3. Vérifier (invite de commandes NEUVE)

- ☐ Ouvrir une nouvelle fenêtre cmd et taper :

```
tesseract --version
```

- ☐ → une version s'affiche (ex. `tesseract v5.x`).

```
tesseract --list-langs
```

- ☐ → la liste contient bien fra (à côté de eng et osd).

4. Paramétrer IAbrain (seulement si non détecté)

IAbrain trouve Tesseract tout seul (PATH + dossier par défaut). Ne faire cette étape que si le journal indique « Tesseract introuvable ».

- ☐ Ouvrir `IAbrain.json`, section "rag", et renseigner le chemin exact :

```
"ocr_tesseract_cmd": "C:\\Program Files\\Tesseract-OCR\\tesseract.exe"
```

- ☐ Réglages voisins (facultatif) : `"ocr_lang": "fra", "ocr_dpi": 300, "ocr_enabled": true`.
- ☐ **Enregistrer, puis redémarrer IAbrain** (ou **Connaissances → Réinitialiser le moteur RAG**) pour qu'il relise la configuration.

5. Tester dans IAbrain

- ☐ Menu «  **RAG perso** » → « **Indexer un dossier complet (récursif)...** ».
- ☐ Vérifier que la case « **OCR des PDF scannés (Tesseract)** » est cochée.
- ☐ Lancer l'indexation sur un dossier contenant un PDF scanné : le journal affiche `OCR page n/N` puis ✓.
- ☐ Poser une question sur ce document : la réponse doit citer la source marquée [perso].

6. Dépannage express

Message dans le journal	Que faire
Failed loading language 'fra' / Error opening ... fra.traineddata	Pack français absent. Relancer l'installateur en cochant « French », ou déposer fra.traineddata dans C:\Program Files\Tesseract-OCR\tessdata\ (Inutile de toucher à TESSDATA_PREFIX.)
OCR indisponible — Tesseract introuvable	Renseigner rag.ocr_tesseract_cmd dans IAbraïn.json (étape 4) puis redémarrer IAbraïn.
OCR : Module pytesseract requis / PyMuPDF requis	(Construction de l'exé) Sur le poste de build : pip install pymupdf pytesseract, puis reconstruire l'exé.
OCR : effectué, aucun texte reconnu	Normal : le document est une photo / page blanche / tampon, sans texte à indexer. Rien à corriger.
Rien ne change après installation / modif JSON	IAbraïn lit la config au démarrage : fermer et rouvrir IAbraïn, puis relancer l'indexation.

Déploiement multi-postes : répéter cette do-list sur **chaque poste** qui indexera des documents scannés — Tesseract est un logiciel externe, non embarqué dans IAbraïn.exe.