

Indexer un dossier et ses sous-dossiers

dans la base RAG personnelle — menu «  RAG perso »

Application : IAbraïn (F1GBD) Version : v1.50.00+ Date : 1er août 2026

Sommaire

1. Objet.....	2
2. À savoir : IAbraïn gère deux bases RAG distinctes	2
3. Prérequis	2
4. Formats de fichiers pris en charge	2
5. Indexer un dossier via le menu «  RAG perso ».....	3
5.1 Ouvrir le panneau	3
5.2 Étape 1 — simulation (recommandé)	3
5.3 Étape 2 — indexation réelle	3
5.4 Options du panneau	3
5.5 Ce que le panneau garantit	3
6. OCR des PDF scannés (conventions signées, arrêtés...).....	4
6.1 Installer Tesseract OCR (Windows)	4
6.2 Vérifier l'installation	4
6.3 Indiquer le chemin à IAbraïn (si non trouvé)	4
6.4 Utiliser	4
7. Autres commandes du menu «  RAG perso ».....	5
8. Vérifier après indexation	5
9. Mettre à jour ou retirer des documents	5
10. Sauvegarde et restauration	5
11. Dépannage	5
12. Récapitulatif express	6

1. Objet

Cette fiche décrit, depuis l'interface d'IAbrain, comment indexer un dossier complet — avec tous ses sous-dossiers et des documents de types variés (PDF, Word, Excel, texte, Markdown, CSV...) — dans la **base de connaissances personnelle**, sans jamais modifier la base de référence ADRASEC.

Résultat : IAbrain retrouve sémantiquement le contenu de vos documents à chaque question, la source personnelle étant discrètement marquée [perso] sous les réponses.

Toutes les opérations se font à la souris, via les menus. Aucun terminal ni ligne de commande n'est nécessaire.

2. À savoir : IAbrain gère deux bases RAG distinctes

IAbrain sépare strictement la documentation officielle de vos ajouts personnels :

Base	Base PRINCIPALE (ADRASEC)	Base PERSO (la vôtre)
Rôle	Référence commune, mise à jour via GitHub (OTA)	Vos propres documents, locaux
Alimentée par	Menu « Connaissances → Indexer / mettre à jour la base »	Menu «  RAG perso » (dossier complet) et « Indexer un fichier »
Mise à jour OTA	Écrasée à chaque mise à jour	Jamais écrasée
Marquage	(aucun)	[perso] sous les réponses

Le menu «  **RAG perso** » écrit **exclusivement dans votre base personnelle**. La base ADRASEC de référence n'est jamais touchée.

3. Prérequis

- **Serveur Ollama actif** (local ou sur votre réseau), tel que configuré dans **Options → Paramètres**.
- **Modèle d'embedding présent** : nomic-embed-text. S'il manque, IAbrain propose de le télécharger ; sinon : **Modèle → Charger (pull) un modèle...** et saisir nomic-embed-text (~270 Mo, tourne sur CPU).
- Les formats PDF, Word et Excel sont pris en charge nativement par la version packagée — **rien à installer**.
- **Pour l'OCR des PDF scannés (facultatif mais recommandé)** : installez **Tesseract OCR** + le pack de langue français sur le poste — **procédure détaillée en section 6**. Sans lui, IAbrain fonctionne normalement mais les PDF scannés restent non indexables.

4. Formats de fichiers pris en charge

Catégorie	Extensions
Pris en charge	.pdf .docx .txt .md .csv .rst .log .json .xml .html .htm
Excel (converti automatiquement)	.xlsx .xlsm (un tableau par feuille)
Non indexés (ignorés)	images, archives, .pptx, .xls (ancien format — à convertir en .xlsx), et tout autre format non listé

PDF : l'extraction se fait par texte, page par page. Un PDF **scanné** (image sans couche texte, ex. convention signée) est désormais **OCR-isé automatiquement** à l'indexation si Tesseract est installé (voir §3) — la progression page par page s'affiche dans le journal. Sans Tesseract, ce PDF est signalé « aucun texte extrait ».

Excel : chaque feuille est convertie en lignes de cellules (séparées par « | ») puis indexée sous le nom du classeur d'origine. Les formules sont lues en valeur calculée.

5. Indexer un dossier via le menu « RAG perso »

5.1 Ouvrir le panneau

Dans la barre de menus :  **RAG perso** → « **Indexer un dossier complet (récursif)...** ». Un panneau dédié s'ouvre.

1. Cliquez « **Parcourir...** » et choisissez le dossier à indexer. Tous ses sous-dossiers seront parcourus.
2. Réglez les **options** souhaitées (voir 5.4).

5.2 Étape 1 — simulation (recommandé)

Cochez « **Simulation (dry-run)** », puis « **► Lancer l'indexation** ». Le panneau affiche le plan — fichiers qui seraient indexés, convertis (Excel) ou ignorés — **sans rien écrire**. C'est le meilleur moyen de vérifier le périmètre avant de lancer réellement.

5.3 Étape 2 — indexation réelle

3. Décochez « **Simulation (dry-run)** ».
4. Cliquez « **► Lancer l'indexation** ». La progression et un journal détaillé s'affichent en direct ; un récapitulatif est ajouté dans le chat à la fin.
5. Activez le RAG : indicateur  RAG dans la barre d'outils, ou **Connaissances** → **Activer l'enrichissement RAG**.

Astuce : une sauvegarde horodatée de votre base perso est créée automatiquement avant toute écriture (option activée par défaut).

5.4 Options du panneau

Option	Effet
Convertir les fichiers Excel	Indexe le contenu des classeurs .xlsx/.xlsm (un tableau par feuille). Décochez pour les ignorer.
Réindexer tout (force)	Retraite tous les fichiers, même ceux qui n'ont pas changé.
Purge des fichiers disparus	Retire de la base les documents supprimés ou déplacés depuis la dernière indexation de ce dossier.
Sauvegarde horodatée avant écriture	Copie la base perso en fichiers .bak avant toute modification (recommandé).
Simulation (dry-run)	Affiche le plan sans rien écrire.
OCR des PDF scannés (Tesseract)	Reconnaît le texte des PDF image (sans couche texte) pour les rendre indexables. Nécessite Tesseract installé (voir §3). Cochée par défaut.
Taille de chunk / Recouvrement	Ajuste le découpage des extraits, en mots (valeurs par défaut convenables dans la plupart des cas).

5.5 Ce que le panneau garantit

- **Incrémental** : seuls les fichiers nouveaux ou modifiés sont retraités (empreinte interne). Relancer sur le même dossier est quasi instantané.
- **Sans doublon** : réindexer un fichier modifié remplace ses anciens extraits.
- **Purge propre** : un fichier supprimé/déplacé est retiré de la base — sans jamais toucher vos autres ajouts personnels ni la base ADRASEC.
- **Sûr** : simulation possible et sauvegarde automatique avant écriture.

6. OCR des PDF scannés (conventions signées, arrêtés...)

De nombreux documents opérationnels sont des PDF **image** (scans de conventions signées, arrêtés, protocoles) : ils ne contiennent aucun texte, et sans OCR ils sont rejetés à l'indexation (« aucun texte extrait »). IAbraïn sait les **OCR-iser automatiquement** — à condition qu'un outil externe, **Tesseract OCR**, soit installé sur le poste avec la langue française.

Cela vaut aussi pour les documents Word (.docx) ne contenant que des images (un scan collé dans Word) : IAbraïn en extrait les images et les OCR-ise de la même façon.

À faire une seule fois par poste. Une fois Tesseract + le pack français installés, l'OCR est automatique pour tous les futurs documents scannés.

6.1 Installer Tesseract OCR (Windows)

6. Téléchargez l'installateur Windows 64 bits maintenu par l'université de Mannheim (référence pour Windows) : le fichier `tesseract-ocr-w64-setup-....exe`.
7. Lancez l'installateur. À l'étape « **Additional language data (download)** », dépliez la liste et **cochez « French »** — **indispensable** : IAbraïn OCR-ise en français par défaut. Laissez le chemin par défaut `C:\Program Files\Tesseract-OCR\`.

⚠ **L'erreur la plus fréquente** : oublier de cocher « French ». Le journal affiche alors `Failed loading language 'fra'`. Dans ce cas, relancez l'installateur et cochez « French », ou déposez le fichier `fra.traineddata` dans `C:\Program Files\Tesseract-OCR\tessdata\` (téléchargeable sur le dépôt `tesseract-ocr/tessdata_fast`).

6.2 Vérifier l'installation

Ouvrez une invite de commandes `cmd` (neuve) et tapez :

```
tesseract --version  
tesseract --list-langs
```

La liste des langues doit contenir `fra` (à côté de `eng` et `osd`). Si `tesseract` n'est pas reconnu, l'outil n'est pas dans le `PATH` — voir 6.3.

6.3 Indiquer le chemin à IAbraïn (si non trouvé)

IAbraïn cherche Tesseract automatiquement (`PATH + C:\Program Files\Tesseract-OCR\`). S'il ne le trouve pas, renseignez le chemin exact dans `IAbraïn.json`, section `rag` :

```
"ocr_tesseract_cmd": "C:\\Program Files\\Tesseract-OCR\\tesseract.exe"
```

Réglages voisins (mêmes section) : `"ocr_enabled": true`, `"ocr_lang": "fra"`, `"ocr_dpi": 300` (baissez à 200 pour accélérer). **Après toute modif de `IAbraïn.json`, redémarrez IAbraïn** (ou Connaissances → Réinitialiser le moteur RAG) pour qu'il relise la configuration.

6.4 Utiliser

Laissez la case « **OCR des PDF scannés (Tesseract)** » cochée dans le panneau (par défaut), puis lancez l'indexation. Les PDF scannés sont OCR-isés à la volée, avec la progression `OCR page n/N` dans le journal. Comptez quelques secondes par page.

7. Autres commandes du menu « RAG perso »

- **Indexer un fichier (base perso)...** : ajoute un seul document. Mode **permanent** (conservé) ou **session** (retiré à la fermeture d'IAbrain).
- **Documents indexés...** : tableau détaillé des fichiers présents dans la base (origine perso / principale).
- **Rechercher dans la base...** : test sémantique direct, sans passer par le LLM — utile pour vérifier qu'un contenu est bien retrouvé.
- **Statistiques de la base...** : nombre de chunks perso, dossier, modèle d'embedding.
- **Vider la base perso...** : efface entièrement votre base personnelle (la base ADRASEC n'est pas concernée).

8. Vérifier après indexation

- **Statistiques** : «  RAG perso → Statistiques de la base... » — le nombre de chunks perso doit avoir augmenté.
- **Documents indexés** : «  RAG perso → Documents indexés... » — vos fichiers apparaissent avec l'origine « perso ».
- **Test sémantique** : «  RAG perso → Rechercher dans la base... » — tapez un terme présent dans un document et vérifiez qu'il ressort.
- **En conversation** : posez une question sur le contenu ; sous la réponse, les sources marquées [perso] confirment que vos documents sont exploités.

9. Mettre à jour ou retirer des documents

Mettre à jour : relancez simplement « Indexer un dossier complet (récursif)... » sur le même dossier. Les fichiers modifiés sont ré-indexés, les autres sautés ; les fichiers disparus sont retirés si l'option de purge est cochée.

Retirer tout : «  RAG perso → Vider la base perso... ». Pour un fichier isolé indexé en mode session, il est retiré automatiquement à la fermeture d'IAbrain.

10. Sauvegarde et restauration

- Avant chaque écriture, IAbrain copie automatiquement votre base perso en fichiers .bak horodatés (si l'option est cochée).
- Sauvegarde manuelle : copiez le dossier de la base personnelle IAbrain_rag_db_perso (situé à côté de l'exécutable).
- Restauration : remplacez le contenu de IAbrain_rag_db_perso par une sauvegarde .bak cohérente (les deux fichiers du même horodatage).

11. Dépannage

Symptôme	Cause probable et remède
Message « modèle d'embedding absent »	Le modèle nomic-embed-text n'est pas sur le serveur. Acceptez le téléchargement proposé, ou Modèle → Charger (pull) un modèle... → nomic-embed-text.
Message d'incompatibilité de dimensions	La base perso a été créée avec un autre modèle d'embedding. Videz la base perso ( RAG perso → Vider la base perso...) puis réindexez avec nomic-embed-text.

Symptôme	Cause probable et remède
OCR : « Failed loading language 'fra' » / « Error opening ... fra.traineddata »	Le pack de langue français de Tesseract manque. Relancez l'installateur Tesseract en cochant « French », ou déposez fra.traineddata dans C:\Program Files\Tesseract-OCR\tessdata\ . Vérifiez avec « tesseract --list-langs ». (Inutile de toucher à TESSDATA_PREFIX.)
OCR : « Tesseract introuvable »	Tesseract n'est pas installé ou pas dans le PATH. Installez-le (voir §6), et/ou renseignez rag.ocr_tesseract_cmd dans IAbraïn.json, puis redémarrez IAbraïn.
OCR : « Module pytesseract requis » / « PyMuPDF requis »	(Construction) L'exé a été compilé sans ces modules Python. Sur le poste de build : pip install pymupdf pytesseract, puis reconstruire l'exé (pyinstaller --clean IAbraïn.spec).
Rien ne change après avoir installé Tesseract / modifié IAbraïn.json	IAbraïn lit la config au démarrage. Fermez et rouvrez IAbraïn (ou Connaissances → Réinitialiser le moteur RAG), puis relancez l'indexation.
OCR : « effectué, aucun texte reconnu (page blanche, photo...) »	Le PDF est bien un scan, mais sans texte lisible (photo, carte d'identité, tampon seul). Ce n'est pas une erreur : il n'y a simplement rien à indexer. Les modules OCR fonctionnent (d'autres PDF passent).
Un .docx donne « aucun texte extrait »	Word contenant seulement des images (scan collé dans Word) : IAbraïn OCR-ise aussi ces images automatiquement (si Tesseract installé). S'il reste vide, c'est que le document ne contient ni texte ni image reconnaissable (ex. image vectorielle EMF/WMF).
Un Excel n'est pas indexé	Classeur .xls (ancien format) : convertissez-le en .xlsx. Ou classeur protégé/corrompu : ouvrez-le et ré-enregistrez-le.
Le contenu n'apparaît pas dans les réponses	Vérifiez que le RAG est activé (indicateur ) , que le fichier est bien présent (Documents indexés...), et augmentez au besoin top_k dans Options → Paramètres.
Indexation lente sur un gros dossier	Normal : les embeddings sont séquentiels (~50-200 ms/extrait). L'OCR d'un PDF scanné ajoute quelques secondes par page. Les relances ne retraitent que les nouveautés.

12. Récapitulatif express

8. **Modèle → Charger (pull) un modèle...** → vérifier/installer nomic-embed-text (une seule fois).
9.  **RAG perso → Indexer un dossier complet (récursif)...** → **Parcourir...** et choisir le dossier.
10. Cocher **Simulation (dry-run)** → ► **Lancer** (aperçu du plan).
11. Décocher **Simulation** → ► **Lancer** (indexation réelle).
12. Activer  RAG. Vos documents personnels sont désormais interrogeables, marqués [perso].