



DOCUMENTATION TECHNIQUE

Conception d'un serveur d'IA local

IAbrian & d-IA sur Ollama — Nœud ACEMAGIC M1A Pro (GPU Intel Arc A770)



Nœud serveur IA M1A Pro en exploitation (écran de démarrage IAbrian)

Projet	Serveur d'IA local pour l'ADRASEC — IAbrian (RAG) & d-IA (dialogue multi-LLM)
Plateforme	ACEMAGIC M1A Pro (TANK) — Intel Arc A770 16 Go — Windows 11 Pro
Moteur d'inférence	Ollama (GPU via backend Vulkan)
Adresse serveur	192.168.1.211 — API sur le port 11434
Auteur	Jean-Louis (F1GBD / F4JHW) — ADRASEC 77 — FNRASEC
Version	v1.1 — 10 juin 2026

Sommaire

1. Présentation et objectifs
 2. Vue d'ensemble de l'architecture
 3. Le matériel : ACEMAGIC M1A Pro
 4. Système d'exploitation et prérequis
 5. Installation et configuration d'Ollama (GPU Vulkan)
 6. IAbrian — assistant RAG local
 7. d-IA — dialogue multi-LLM autonome
 8. Accès distant (RDP) et exploitation remote
 9. Réseau autonome de terrain — Beryl 7 (hors-ligne)
 10. Démarrage automatique et autonomie headless
 11. Vérifications, maintenance et dépannage
 12. Récapitulatif des accès et checklist
- Annexe — Commandes utiles

1. Présentation et objectifs

IAbrian est un assistant d'intelligence artificielle local conçu pour la sécurité civile : il répond aux questions des opérateurs à partir d'une base documentaire ADRASEC (technique RAG — génération augmentée par récupération) et fonctionne entièrement hors-ligne. d-IA est un système complémentaire de dialogue autonome entre plusieurs modèles de langage. Tous deux s'appuient sur Ollama, un moteur d'inférence exécuté localement.

L'objet de ce document est de décrire la conception d'un nœud serveur dédié — le M1A Pro — qui centralise l'inférence sur un GPU et la met à disposition de tous les opérateurs du réseau, sans aucune dépendance à Internet, au réseau cellulaire ou à un DNS externe.

Objectifs

- Mutualiser un GPU performant (Intel Arc A770 16 Go) pour servir plusieurs postes clients.
- Garantir une autonomie totale : fonctionnement en zone blanche, sans Internet ni GSM.
- Préserver la confidentialité : aucune donnée ne quitte le réseau local.
- Assurer un démarrage et un accès distant sans écran ni clavier (mode headless).

2. Vue d'ensemble de l'architecture

Le M1A Pro joue le rôle de serveur d'inférence : Ollama y héberge les modèles et expose une API sur le port 11434. IAbrian et d-IA sont des applications clientes qui consomment cette API — qu'elles s'exécutent sur le M1A lui-même ou sur d'autres postes du réseau.

Chaîne de bout en bout : Opérateurs (IAbrian / d-IA / navigateur) → réseau local (QG ou routeur Beryl 7) → M1A Pro 192.168.1.211 : Ollama (GPU, port 11434) + Bureau à distance (port 3389). Aucun accès Internet requis.

Deux plans d'usage coexistent :

- Inférence : les clients interrogent l'API Ollama du serveur (port 11434) — c'est l'usage principal.
- Administration : prise de contrôle du bureau du serveur en RDP (port 3389) pour la maintenance.

3. Le matériel : ACEMAGIC M1A Pro



ACEMAGIC M1A Pro (TANK) — mini-PC à GPU dédié

Le M1A Pro est un mini-PC compact embarquant un GPU dédié, ce qui le rend particulièrement adapté à l'inférence de modèles de langage tout en restant transportable.

Composant	Caractéristique
Processeur	Intel Core i9-13900HK
GPU	Intel Arc A770 – 16 Go GDDR6
Mémoire	32 Go DDR5
Réseau	Ethernet (compatible 2,5 GbE via le routeur) + Wi-Fi

Composant	Caractéristique
Connectique	USB-A, USB-C / Thunderbolt, lecteur SD, audio 3,5 mm
Refroidissement	Ventilation active (fonctionnement soutenu)
Pourquoi ce choix : Les 16 Go de VRAM permettent de charger confortablement des modèles de 7 à 14 milliards de paramètres avec leur contexte ; le format compact et l'alimentation modeste conviennent à un poste de QG ; le GPU accélère l'inférence d'un facteur 3 à 4 par rapport au CPU seul.	

4. Système d'exploitation et prérequis

- Windows 11 Pro (l'édition Pro est requise pour le Bureau à distance natif).
- Pilotes Intel Arc à jour — ils fournissent le runtime Vulkan utilisé pour l'accélération GPU.
- Deux comptes Windows :

Compte	Rôle
xxxxx (compte Microsoft)	Session principale : héberge le serveur Ollama (GPU) et démarre en auto- logon
RDPadmin (compte local admin)	Accès distant d'administration (RDP), client Ollama

5. Installation et configuration d'Ollama (GPU Vulkan)

Ollama est le moteur d'inférence. Son installateur officiel l'installe pour l'utilisateur courant et le configure pour démarrer automatiquement à l'ouverture de session.

5.1 Variables d'environnement (au niveau Utilisateur)

Ces variables conditionnent l'écoute réseau et l'activation du GPU. À définir pour le compte xxxxx :

Variable	Valeur	Rôle
OLLAMA_HOST	0.0.0.0:11434	Écoute sur tout le réseau
OLLAMA_VULKAN	1	Active le GPU Arc (Vulkan)
OLLAMA_FLASH_ATTENTION	0	Optimisation Vulkan
OLLAMA_KEEP_ALIVE	-1	Garde les modèles en VRAM

```
[Environment]::SetEnvironmentVariable("OLLAMA_VULKAN", "1", "User")
```

Point clé : Les variables ne sont lues qu'au DÉMARRAGE du serveur Ollama. Après les avoir définies, quitter Ollama (icône de la barre des tâches → Quit) puis le relancer — la commande « ollama run » seule ne redémarre PAS le serveur.

5.2 Modèles

Téléchargement initial (nécessite Internet une seule fois ; ensuite tout fonctionne hors-ligne) :

```
ollama pull qwen2.5:7b / ollama pull bge-m3 / ollama pull nomic-embed-text
```

Modèle	Rôle	Usage
qwen2.5:7b	Génération	Réponses, rédaction
llama3.2:3b	Génération légère	Réponses rapides
bge-m3	Reranking	Tri des passages RAG
nomic-embed-text	Embeddings	Vectorisation (768 dim)

5.3 Vérification du GPU

```
ollama run qwen2.5:7b "test" --verbose ollama ps
```

La colonne PROCESSOR doit indiquer un pourcentage GPU, et le débit avoisiner 40 tokens/seconde sur qwen2.5:7b. Le journal du serveur (server.log) doit mentionner le chargement sur « Vulkan0 ».

6. IAbraïn — assistant RAG local



IAbraïn interroge une base documentaire ADRASEC vectorisée (environ 3 760 fragments indexés avec nomic-embed-text en 768 dimensions), applique un reranking (bge-m3) pour sélectionner les meilleurs passages, puis génère la réponse avec qwen2.5:7b — le tout via le serveur Ollama du M1A.

Configuration cliente

Dans IAbraïn, l'adresse du serveur d'inférence se règle par le paramètre `base_url` :

Cas	base_url
IAbraïn sur le M1A lui-même	<code>http://localhost:11434</code>
IAbraïn sur un autre poste du réseau	<code>http://192.168.1.211:11434</code>

Capacités principales

- Questions / réponses sur la documentation technique et opérationnelle ADRASEC.
- Rédaction assistée (SITREP, messages, synthèses) et macros conversationnelles.
- Greffons (plugins) : météo aéronautique, etc., et pipeline vocal (reconnaissance et synthèse).
- Base de connaissances partagée : un pack RAG commun est diffusé et mis à jour pour toutes les ADRASEC.

7. d-IA — dialogue multi-LLM autonome

d-IA orchestre un dialogue autonome entre trois modèles de langage jouant des rôles distincts — Investigateur, Analyste et Modérateur — afin d'explorer un sujet en profondeur. Il s'appuie sur le même serveur Ollama que IAbraïn.

- Les trois rôles dialoguent par tours ; le Modérateur recadre périodiquement la discussion.
- Les conclusions peuvent être exportées vers IAbraïn (zone de validation) pour enrichir la base.
- Une recherche web optionnelle (DuckDuckGo / SearXNG) peut être activée — à désactiver pour un fonctionnement strictement hors-ligne.

8. Accès distant (RDP) et exploitation remote

L'administration du serveur se fait par Bureau à distance ; l'usage courant de l'IA ne nécessite, lui, aucune prise de contrôle — il suffit d'interroger l'API.

8.1 Prise de contrôle du bureau (administration)

1. Vérifier la connectivité :

```
Test-NetConnection 192.168.1.211 -Port 3389
```

2. Ouvrir la session :

```
mstsc /v:192.168.1.211
```

3. S'identifier avec le compte local : utilisateur 192.168.1.211\RDPadmin et son mot de passe (jamais le code PIN).

Un raccourci bureau pré-configuré (généré par le script Create-M1A-Shortcut.ps1) permet une connexion en un double-clic.

8.2 Utilisation de l'IA à distance

Depuis n'importe quel poste du réseau, pointer IAbraïn / d-IA (ou tout client) sur `http://192.168.1.211:11434`. Plusieurs opérateurs peuvent interroger le serveur simultanément ; Ollama traite les requêtes en file. Vérification :

```
curl http://192.168.1.211:11434/api/version
```

9. Réseau autonome de terrain — Beryl 7 (hors-ligne)



GL.iNet Beryl 7 (GL-MT3600BE) — routeur Wi-Fi 7 portable

Pour un déploiement en zone blanche, le mini-routeur Beryl 7 crée un réseau Wi-Fi autonome auquel le M1A et les postes clients se connectent — sans aucun accès Internet.

Caractéristique	Beryl 7 (GL-MT3600BE)
Wi-Fi	Wi-Fi 7 bi-bande (2,4 + 5 GHz)
Ethernet	2x ports 2,5 GbE (WAN/LAN configurables)
Alimentation	USB-C PD (batterie externe possible)
Système	OpenWrt (firmware GL.iNet)

Configuration en point d'accès autonome

1. Alimenter le Beryl (USB-C, secteur ou batterie) ; ne RIEN brancher sur le port WAN.
2. Accéder à l'administration (<http://192.168.8.1>) et définir le mot de passe.
3. Fixer le LAN à 192.168.1.0/24 (routeur en 192.168.1.1) pour préserver l'adressage du M1A et conserver tous les réglages existants.
4. Créer le Wi-Fi (SSID « ADRASEC-IA », WPA2/WPA3, mot de passe robuste).
5. Raccorder le M1A en Ethernet 2,5 GbE et lui réserver l'IP 192.168.1.211 (bail DHCP statique sur son adresse MAC).

Les opérateurs se connectent alors au Wi-Fi « ADRASEC-IA » et accèdent au serveur — RDP et IA — exactement comme sur le réseau du QG. L'absence d'Internet est normale et sans effet sur l'usage local.

10. Démarrage automatique et autonomie headless

Pour que le serveur soit opérationnel dès la mise sous tension, sans écran ni intervention :

- Auto-logon du compte xxxxx : la session s'ouvre seule au démarrage, ce qui lance Ollama (avec le GPU) automatiquement.
- Mise en veille désactivée : le serveur reste joignable en permanence.
- Bouchon HDMI factice : garantit une résolution d'affichage correcte en RDP, écran débranché.

Résultat : Au démarrage : la session xxxxx s'ouvre → Ollama démarre sur le GPU → l'API répond sur le port 11434 pour tout le réseau, en moins d'une minute, sans aucune intervention.

Démarrage à froid (cold boot) : fiabiliser l'auto-logon

Toute l'autonomie headless repose sur un point unique : l'ouverture de session automatique de xxxxx doit réellement se produire à la mise sous tension. Si elle n'a pas lieu, le poste reste sur l'écran de connexion, Ollama n'est jamais lancé et l'API reste injoignable — les clients IAbrian / d-IA ne trouvent personne sur le port 11434 tant qu'on ne se logue pas manuellement sur le M1A.

Cause la plus fréquente d'un cold boot bloqué : la clé d'auto-logon est bien posée (AutoAdminLogon = 1, nom d'utilisateur) mais le mot de passe n'est pas mémorisé, ou le secret a été invalidé (changement de

mot de passe, mise à jour Windows forçant l'écran de verrouillage, démarrage rapide). Pour un fonctionnement réellement sans intervention, finaliser et durcir l'auto-logon :

1. Finaliser l'auto-logon avec Sysinternals Autologon : il enregistre le mot de passe sous forme de secret chiffré (LSA), seul moyen fiable de le persister — autologon.exe xxxxx <NomMachine> <MotDePasse>. (Poser AutoAdminLogon = 1 dans le registre sans mot de passe ne suffit pas.)
2. Désactiver le démarrage rapide de Windows (Fast Startup) pour que chaque arrêt produise un vrai démarrage à froid, à l'état prévisible — utile après une coupure secteur en mission.
3. Régler le BIOS du M1A sur « Restore on AC Power Loss → Power On » : après une coupure de courant, le poste se rallume seul et toute la chaîne suit automatiquement.
4. Filet de sécurité (optionnel) : une tâche planifiée déclenchée à l'ouverture de session relance Ollama au besoin, doublée d'un watchdog qui sonde /api/version toutes les quelques minutes et le redémarre s'il tombe (script Setup-OllamaAutoStart.ps1).

À ne pas faire : exécuter Ollama en service Windows pour le démarrer avant la session. En session 0 (sans bureau interactif), l'initialisation GPU de l'Arc A770 est instable et retombe sur le CPU — on perd l'accélération (~40 tok/s). Le serveur doit tourner dans la session interactive de xxxxx ; c'est l'auto-logon, pas un service, qui le lance.

Validation : redémarrer le M1A à froid sans toucher au clavier ni à la souris, puis depuis un poste du réseau : curl http://192.168.1.211:11434/api/version doit renvoyer 200 / la version.

11. Vérifications, maintenance et dépannage

Symptôme	À vérifier
RDP refuse la connexion	Test-NetConnection:3389 = True ; pare-feu ; profil réseau Privé ; M1A réveillé
Identifiants refusés	Mot de passe du compte (jamais le PIN) ; préfixe 192.168.1.211\ pour le compte local
IA injoignable	Session xxxxx ouverte ; curl:11434 = 200 ; OLLAMA_HOST = 0.0.0.0
Modèles en 100% CPU	OLLAMA_VULKAN = 1 (variable User) puis REDÉMARRER le serveur Ollama
Débit anormalement bas	Vérifier que le GPU sélectionné est bien l'Arc A770 (et non l'iGPU intégré)
Cold boot : IA injoignable, rien ne démarre	Auto-logon non déclenché (poste resté sur l'écran de connexion) : finaliser le secret avec Sysinternals Autologon ; désactiver le démarrage rapide ; BIOS « Restore on AC Power Loss → Power On »

Maintenance de la base RAG : l'ajout de documents, l'enrichissement et la mesure de non-régression s'effectuent avec l'outillage dédié (enrichissement des titres, ajout incrémental, inventaire, benchmark), documenté dans la fiche réflexe de maintenance.

12. Récapitulatif des accès et checklist

Service	Adresse	Identifiants
Bureau M1A (RDP)	192.168.1.211:3389	192.168.1.211\RDPadmin + mdp
Serveur IA (Ollama)	http://192.168.1.211:11434	—
Administration Beryl 7	http://192.168.1.1	compte admin du routeur

Checklist de mise en service

- ☐ Pilotes Intel Arc à jour ; Ollama installé et démarré au logon
- ☐ Variables OLLAMA_VULKAN=1 et OLLAMA_HOST=0.0.0.0 définies (compte xxxxx)
- ☐ Modèles téléchargés (qwen2.5:7b, bge-m3, nomic-embed-text)
- ☐ GPU confirmé actif (ollama ps = GPU, ~40 tok/s)
- ☐ Bureau à distance activé, pare-feu 3389, auto-logon xxxxx
- ☐ Test RDP et test IA réussis depuis un poste du réseau
- ☐ Auto-logon finalisé (secret LSA via Autologon.exe), démarrage rapide désactivé — validé par un vrai redémarrage à froid

Annexe — Commandes utiles

Action	Commande
Vérifier l'API	<code>curl http://192.168.1.211:11434/api/version</code>
État des modèles chargés	<code>ollama ps</code>
Test de génération	<code>ollama run qwen2.5:7b "test" --verbose</code>
Activer le GPU (Vulkan)	<code>[Environment]::SetEnvironmentVariable("OLLAMA_VULKAN","1","User")</code>
Tester l'accès RDP	<code>Test-NetConnection 192.168.1.211 -Port 3389</code>
Ouvrir le Bureau à distance	<code>mstsc /v:192.168.1.211</code>

73 de F1GBD — ADRASEC 77 — FNRASEC