

PROCÉDURE**Démarrage automatique d'Ollama au cold-boot — Auto-logon du nœud A7 Max**

Nœud IAbraïn Geekom A7 Max (Ryzen 9 7940HS, Radeon 780M / backend Vulkan) — autonomie headless

ADRASEC 77 · FNRASEC Réf. PROC_A7MAX_Autologin Ollama 0.30.7 12 juin 2026 F1GBD

1. Objet et principe

À la mise sous tension (ou après une coupure secteur), le A7 Max doit ouvrir seul une session Windows et lancer Ollama sur le GPU, sans clavier ni écran, afin qu'IAbraïn s'y connecte par le réseau. Cette procédure établit cette autonomie de cold-boot.

Principe retenu : on ne passe pas Ollama en service Windows. Un service tourne en session 0 sans bureau interactif, où l'initialisation du GPU est instable et retombe sur le CPU. On fiabilise donc une session interactive sur deux fronts : auto-logon de l'opérateur, puis lancement d'Ollama par une tâche planifiée robuste doublée d'un watchdog.

Point spécifique au A7 Max : comme Ollama est démarré par une tâche planifiée (et non depuis ta console), les variables d'activation GPU doivent être posées au scope Machine. En scope User elles ne seraient pas vues par le serveur lancé par la tâche, et le cold-boot repartirait en CPU.

Valeurs à adapter avant d'appliquer la procédure

Compte opérateur : user (le compte dont l'ouverture de session lance Ollama)

Nom de la machine : <NOM_A7MAX> — obtenir avec hostname OU \$env:COMPUTERNAME

Adresse IP LAN : <IP_A7MAX> — obtenir avec ipconfig

Lanceur Ollama : C:\Users\user\AppData\Local\Programs\Ollama\ollama app.exe

Port d'écoute : 11434

2. Prérequis

- Console PowerShell **Administrateur** (les étapes scope Machine et registre l'exigent).
- Ollama installé en version Vulkan officielle, déjà fonctionnel en GPU en session interactive (cf. fiche « Correction Ollama v0.30.x — Vulkan / iGPU »).
- Sysinternals Autologon64.exe téléchargé (learn.microsoft.com/sysinternals/downloads/autologon).
- Connexion Windows par mot de passe : l'option « Windows Hello uniquement / sans mot de passe » doit être désactivée (voir étape 2).

3. Étape 1 — Variables GPU au scope Machine (clé de l'autonomie)

En console Administrateur, poser les variables que le serveur Ollama lancé par la tâche devra hériter :

```
# Console PowerShell ADMINISTRATEUR — scope Machine
[Environment]::SetEnvironmentVariable("OLLAMA_VULKAN", "1", "Machine")
[Environment]::SetEnvironmentVariable("OLLAMA_IGPU_ENABLE", "1", "Machine")
[Environment]::SetEnvironmentVariable("OLLAMA_KV_CACHE_TYPE", "f16", "Machine")
[Environment]::SetEnvironmentVariable("OLLAMA_FLASH_ATTENTION", "0", "Machine")
```

```
# Ecoute reseau pour que IABrain (clients du LAN) atteigne le serveur
[Environment]::SetEnvironmentVariable("OLLAMA_HOST","0.0.0.0:11434","Machine")
```

Rappels : OLLAMA_VULKAN + OLLAMA_IGPU_ENABLE activent le GPU intégré sous la 0.30.x ; OLLAMA_KV_CACHE_TYPE=f16 évite l'erreur 500 « V cache requires flash_attn » ; Flash Attention reste désactivé (convention RAG).

4. Étape 2 — Autoriser la connexion par mot de passe

Sous Windows 11, tant que la connexion sans mot de passe est imposée, Autologon ne peut pas enregistrer le secret. Désactiver l'option :

- Paramètres → Comptes → Options de connexion → désactiver « Pour renforcer la sécurité, n'autoriser que la connexion Windows Hello pour les comptes Microsoft ».

5. Étape 3 — Auto-logon (Sysinternals Autologon)

Autologon enregistre le secret chiffré dans la base LSA (et non un mot de passe en clair dans le registre). C'est l'étape qui débloque le cold-boot resté sur l'écran de connexion.

```
# Ligne de commande (adapter le nom machine et le mot de passe)
.\Autologon64.exe user <NOM_A7MAX> <MotDePasse>

# Variante : lancer Autologon64.exe sans argument, remplir
# Username / Domain / Password, puis cliquer Enable.
```

Le domaine est le nom local de la machine (poste hors domaine). Après cette étape, l'ouverture de session de user est automatique au démarrage.

6. Étape 4 — Cold-boot propre (désactiver le démarrage rapide)

Pour qu'un arrêt produise un vrai démarrage à froid, à l'état prévisible après coupure secteur :

```
Set-ItemProperty -Path "HKLM:\SYSTEM\CurrentControlSet\Control\Session Manager\Power" `
-Name "HiberbootEnabled" -Value 0
```

7. Étape 5 — Lancement d'Ollama au logon (tâche planifiée)

On remplace le raccourci fragile du dossier Démarrage par une tâche planifiée avec délai et relance automatique. D'abord, supprimer l'éventuel raccourci natif pour éviter un double lancement (sinon « bind: address already in use ») :

- Exécuter `shell:startup` et supprimer `ollama.lnk` s'il est présent.

Puis créer la tâche (console Administrateur). Le lanceur est « ollama app.exe » — l'application tray qui démarre le serveur — et non le binaire `ollama.exe` nu :

```
$op      = "$env:COMPUTERNAME\user"
$launcher = "C:\Users\user\AppData\Local\Programs\Ollama\ollama app.exe"

$action   = New-ScheduledTaskAction -Execute $launcher
$trigger  = New-ScheduledTaskTrigger -AtLogOn -User $op
$trigger.Delay = "PT20S" # 20 s : GPU + reseau prêts
$principal = New-ScheduledTaskPrincipal -UserId $op `
-LogonType Interactive -RunLevel Highest
```

```
$settings = New-ScheduledTaskSettingsSet -AllowStartIfOnBatteries `
    -DontStopIfGoingOnBatteries -StartWhenAvailable `
    -ExecutionTimeLimit ([TimeSpan]::Zero) `
    -RestartCount 3 -RestartInterval (New-TimeSpan -Minutes 1) `
    -MultipleInstances IgnoreNew

Register-ScheduledTask -TaskName "IAbrain-Ollama-Start" `
    -Action $action -Trigger $trigger -Principal $principal -Settings $settings `
    -Description "Démarrage Ollama (GPU Radeon 780M / Vulkan) au logon de user."
```

8. Étape 6 — Watchdog (sonde et relance)

Créer le script de sonde, qui relance Ollama si le serveur ne répond plus :

```
# Fichier : C:\headless\Ollama-Watchdog.ps1
$launcher = "C:\Users\user\AppData\Local\Programs\Ollama\ollama app.exe"
try {
    $rep = Invoke-WebRequest -UseBasicParsing -TimeoutSec 5 `
        -Uri "http://127.0.0.1:11434/api/version"
    if ($rep.StatusCode -ne 200) { throw }
} catch {
    Start-Process $launcher
}
```

Puis la tâche qui l'exécute toutes les 3 minutes, dans la session interactive de user :

```
$op = "$env:COMPUTERNAME\user"
$act = New-ScheduledTaskAction -Execute "powershell.exe" `
    -Argument "-NoProfile -ExecutionPolicy Bypass -File C:\headless\Ollama-Watchdog.ps1"
$trg = New-ScheduledTaskTrigger -AtLogOn -User $op
$trg.Repetition = (New-ScheduledTaskTrigger -Once -At (Get-Date) `
    -RepetitionInterval (New-TimeSpan -Minutes 3)).Repetition
$prn = New-ScheduledTaskPrincipal -UserId $op -LogonType Interactive
$set = New-ScheduledTaskSettingsSet -StartWhenAvailable -MultipleInstances IgnoreNew
Register-ScheduledTask -TaskName "IAbrain-Ollama-Watchdog" `
    -Action $act -Trigger $trg -Principal $prn -Settings $set `
    -Description "Sonde /api/version toutes les 3 min et relance Ollama si besoin."
```

Astuce : les étapes 5 et 6 sont automatisées par ton script compagnon Setup-OllamaAutoStart.ps1, à lancer avec -OllamaLauncher pointant sur « ollama app.exe » et -OperatorUser user.

9. Étape 7 — BIOS : redémarrage après coupure secteur

Pour que le A7 Max reparte seul après une coupure, régler dans le BIOS :

- « Restore on AC Power Loss » → **Power On** (selon le BIOS : « AC Back » / « After Power Failure » → « Always On »).

10. Procédure de test (cold-boot réel)

1. Arrêter complètement le poste (arrêt, pas mise en veille). Attendre quelques secondes, rallumer, **sans toucher clavier ni souris**.
2. Depuis un client du LAN : `curl http://<IP_A7MAX>:11434/api/version` → réponse 200 + version.

3. En local ou RDP : `Get-ScheduledTask IAbraIn-Ollama-* | Get-ScheduledTaskInfo → LastTaskResult = 0.`
4. Vérifier le GPU : `ollama ps → colonne PROCESSOR à 100% GPU` (confirme que les variables Machine sont bien héritées).

Résultat attendu :

```
curl http://<IP_A7MAX>:11434/api/version
{"version":"0.30.7"}
```

```
ollama ps
NAME          ID          SIZE    PROCESSOR  CONTEXT
qwen2.5:7b    845dbda0ea48 4.9 GB  100% GPU   4096
```

11. Dépannage

Symptôme	Cause probable	Action
Bloqué sur l'écran de connexion au cold-boot	Secret d'auto-logon absent de la base LSA	Relancer Autologon64.exe user <NOM_A7MAX> <MDP>
Ollama démarre mais reste à 100 % CPU	Variables Vulkan posées en User, non vues par la tâche	Poser VULKAN / IGPU_ENABLE / KV en scope Machine
Erreur 500 « V cache requires flash_attn »	Cache KV quantifié + Flash Attention désactivé	OLLAMA_KV_CACHE_TYPE=f16 (Machine)
bind: address already in use	Double lancement (raccourci Démarrage + tâche)	Supprimer Ollama.lnk dans shell:startup
IAbraIn ne joint pas le serveur	OLLAMA_HOST limité à 127.0.0.1, ou pare-feu	OLLAMA_HOST=0.0.0.0:11434 (Machine) + règle pare-feu 11434
Session non ouverte après le login auto	Connexion sans mot de passe encore imposée	Désactiver « Windows Hello uniquement » puis relancer Autologon

12. Récapitulatif express

Console PowerShell Administrateur, une passe, puis Autologon et reboot :

```
[Environment]::SetEnvironmentVariable("OLLAMA_VULKAN","1","Machine")
[Environment]::SetEnvironmentVariable("OLLAMA_IGPU_ENABLE","1","Machine")
[Environment]::SetEnvironmentVariable("OLLAMA_KV_CACHE_TYPE","f16","Machine")
[Environment]::SetEnvironmentVariable("OLLAMA_FLASH_ATTENTION","0","Machine")
[Environment]::SetEnvironmentVariable("OLLAMA_HOST","0.0.0.0:11434","Machine")
Set-ItemProperty "HKLM:\SYSTEM\CurrentControlSet\Control\Session Manager\Power" `
-Name HiberbootEnabled -Value 0

# Tâches login + watchdog : voir étapes 5-6 (ou Setup-OllamaAutoStart.ps1)
# Auto-logon : .\Autologon64.exe user <NOM_A7MAX> <MotDePasse>
# Puis : arrêt complet -> rallumage sans clavier -> test curl /api/version
```