

OPTIMISATION D'UN SERVEUR OLLAMA LOCAL

sur mini-PC AMD Ryzen avec iGPU Radeon



Guide pratique, scripts d'automatisation et benchmarks

Version 4.1 — Avec benchmarks IAbraIn et stratégie multi-modèles

Nouveautés version 4.1 : Cette version mineure ajoute un retour d'expérience sur l'usage réel via IAbraIn (interface client) en complément des benchmarks CLI Ollama. Trois modèles ont été comparés sur le LX15 Pro (Mistral Nemo 12B, Qwen 2.5 7B, Llama 3.2 3B) avec mesure des tokens/s et analyse qualité. Recommandation d'une stratégie multi-modèles selon le cas d'usage, avec mise en garde sur la qualité technique des modèles $\leq 3B$ parameters pour la rédaction ADRASEC.

Nouveautés version 4 (rappel) : Section 9 dédiée à l'allocation BIOS de VRAM dédiée selon l'architecture iGPU. Tests réalisés sur APU Vega 8 montrent qu'une allocation manuelle (UMA_SPECIFIED) dégrade les performances de 28 % par rapport au mode Auto sur cette génération. Recommandations différenciées par architecture (Vega vs RDNA3).

Contexte d'usage ADRASEC : Mise en service d'un serveur LLM local (Ollama) sur mini-PC pour assister la rédaction de scénarios d'exercice, de RETEX, de documents FNRASEC, et l'analyse de logs ou de traces radio. Le présent document décrit la procédure d'optimisation permettant de passer d'une exécution CPU pure à une exécution GPU via Vulkan, sans achat de matériel supplémentaire.

Sommaire

- 1. Choix du matériel selon l'architecture iGPU
- 2. Configurations de référence testées
- 3. Problème constaté et diagnostic
- 4. Procédure d'optimisation — méthode interface graphique
- 5. Procédure d'optimisation — script PowerShell tout-en-un
- 6. Script PowerShell autonome (.ps1) clé en main
- 7. Vérification du fonctionnement
- 8. Résultats mesurés et benchmarks
- 9. Allocation BIOS de VRAM dédiée — recommandations par architecture (NOUVEAU)
- 10. Résolution des erreurs d'allocation mémoire
- 11. Choix du modèle LLM — recommandations, benchmarks IAbraIn et stratégie multi-modèles
- 12. Mise à jour et maintenance d'Ollama
- 13. Faut-il passer de 32 à 64 Go de DDR4/DDR5 ?
- 14. To-do list récapitulative
- 15. Conseils pour le déploiement en ADRASEC

1. Choix du matériel selon l'architecture iGPU

Avant toute mise en service d'un serveur Ollama local, il est essentiel d'identifier précisément l'architecture iGPU du mini-PC ciblé. Tous les processeurs AMD Ryzen mobiles ne sont pas équivalents pour l'inférence LLM, et l'écart de performance entre deux générations peut être de l'ordre de 2 à 3 fois.

1.1. Tableau comparatif des iGPU AMD

Génération CPU	Architecture iGPU	Exemples iGPU	RAM type	Perf LLM relative
Ryzen 5000U (2021)	Vega 7 / Vega 8	Radeon Graphics	DDR4-3200	× 1 (base)
Ryzen 6000H (2022)	RDNA 2	Radeon 660M, 680M	DDR5-4800	× 1,8
Ryzen 7000HS (2023)	RDNA 3	Radeon 760M, 780M	DDR5-5600	× 2,5
Ryzen 8040HS (2024)	RDNA 3 + NPU	Radeon 780M, 880M	DDR5-5600	× 2,5-3
Ryzen AI 300 (2024)	RDNA 3.5 + NPU XDNA2	Radeon 880M, 890M	LPDDR5X-7500	× 3-4

1.2. Recommandation pour un serveur ADRASEC

- Ryzen 7000HS / 7040HS / 7940HS (Radeon 780M, DDR5) — meilleur compromis 2026
- Ryzen 8845HS / 8945HS (Radeon 780M + NPU) — équivalent aux 7000HS avec NPU
- Ryzen AI 9 HX 370 / 9 365 — déploiements neufs haut de gamme

Les mini-PC à base de Ryzen 5000U restent utilisables avec des modèles plus petits (7B) et des performances limitées (~7 tokens/s en génération). Voir section 9 pour les précautions BIOS spécifiques à cette architecture.

2. Configurations de référence testées

2.1. Configuration A — Geekom A7 Max (RDNA3 moderne)

Élément	Détail
Processeur	AMD Ryzen 9 7940HS (8C/16T, Zen 4)
iGPU	AMD Radeon 780M (RDNA 3, 12 CU, gfx1103)
Mémoire vive	32 Go DDR5-4800 dual channel
VRAM dédiée (BIOS Auto)	3,9 Go

2.2. Configuration B — LX15 Pro (Vega 8, génération précédente)

Élément	Détail
Processeur	AMD Ryzen 7 5825U (8C/16T, Zen 3+)
iGPU	AMD Radeon Vega 8 (GCN 5.1, 8 CU)
Mémoire vive	32 Go DDR4-3200 dual channel (Channel A + B)
VRAM dédiée (BIOS Auto)	0,48 Go
BIOS Aptio AMI	Onglet Advanced accessible (contrairement au Geekom A7 Max)

3. Problème constaté et diagnostic

À l'installation par défaut sous Windows, Ollama n'exploite PAS l'iGPU Radeon AMD et tourne en mode 100 % CPU. Ce kit permet d'activer le backend Vulkan pour utiliser l'iGPU.

3.1. Diagnostic en 4 commandes

```
ollama --version
ollama run mistral-nemo:12b --verbose
ollama ps
Get-Content "$env:LOCALAPPDATA\Ollama\server.log" -Tail 100 | Select-String
"VULKAN|compute"
```

4. Procédure d'optimisation — méthode interface graphique

4.1. Activer Vulkan dans Ollama

1. Touche Windows → taper « variables d'environnement » → ouvrir « Modifier les variables d'environnement pour votre compte ».
2. Section « Variables utilisateur » → bouton « Nouvelle... ».
3. Nom = OLLAMA_VULKAN, Valeur = 1, OK.

4.2. Désactiver Flash Attention (critique pour Vulkan AMD)

1. Section « Variables système » → bouton « Nouvelle... ».
2. Nom = OLLAMA_FLASH_ATTENTION, Valeur = 0, OK.

4.3. Variables système complémentaires recommandées

Nom	Valeur	Rôle
OLLAMA_HOST	http://0.0.0.0:11434	Expose le serveur sur le LAN
OLLAMA_KEEP_ALIVE	30m	Maintien du modèle 30 min en mémoire
OLLAMA_KV_CACHE_TYPE	q8_0	KV cache quantifié, économise la VRAM

OLLAMA_CONTEXT_LENGTH	8192	Contexte par défaut
OLLAMA_NUM_BATCH	256	Batch réduit pour économiser VRAM

5. Procédure d'optimisation — script PowerShell tout-en-un

Méthode rapide : ouvrir PowerShell en administrateur (clic droit → Exécuter en tant qu'administrateur), puis copier-coller le bloc suivant :

```
# === Configuration Ollama optimisée pour iGPU AMD Radeon ===
# F1GBD / ADRASEC 77

[System.Environment]::SetEnvironmentVariable('OLLAMA_VULKAN', '1', 'User')
[System.Environment]::SetEnvironmentVariable('HSA_OVERRIDE_GFX_VERSION', $null, 'User')

[System.Environment]::SetEnvironmentVariable('OLLAMA_FLASH_ATTENTION', '0', 'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_KV_CACHE_TYPE', 'q8_0', 'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_KEEP_ALIVE', '30m', 'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_MAX_LOADED_MODELS', '2', 'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_HOST', 'http://0.0.0.0:11434', 'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_NUM_PARALLEL', '1', 'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_CONTEXT_LENGTH', '8192', 'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_NUM_BATCH', '256', 'Machine')

Write-Host "Configuration terminée. Redémarrer Ollama." -ForegroundColor Green
```

6. Script PowerShell autonome (.ps1) clé en main

Pour un déploiement homogène sur plusieurs postes ADRASEC, le script Configure-OllamaAMD.ps1 est mis à disposition. Il offre 4 modes :

- Apply (défaut) : applique la configuration optimale
- Check : audite la configuration actuelle sans modification
- Restore : restaure la configuration Ollama par défaut
- Bench : affiche les commandes pour mesurer les performances

Le script effectue automatiquement :

- Vérification des droits administrateur
- Détection automatique du matériel (CPU, RAM, iGPU, VRAM dédiée)
- Recommandation automatique des paramètres selon la VRAM détectée
- Application des variables d'environnement

- Proposition de redémarrage Ollama automatisé

6.1. Utilisation

Autoriser l'exécution des scripts (une seule fois) :

```
Set-ExecutionPolicy -Scope CurrentUser -ExecutionPolicy RemoteSigned
```

Débloquer le fichier téléchargé :

```
Unblock-File -Path .\Configure-OllamaAMD.ps1
```

Lancer :

```
.\Configure-OllamaAMD.ps1
```

7. Vérification du fonctionnement

```
Get-Content "$env:LOCALAPPDATA\Ollama\server.log" -Tail 60 | Select-String  
"Vulkan|library|VRAM"
```

Lignes attendues :

```
OLLAMA_VULKAN:true  
inference compute id=... library=Vulkan name=Vulkan0  
description="AMD Radeon ... Graphics" type=iGPU
```

Test final :

```
ollama run mistral-nemo:12b --verbose  
>>> Écris un texte de 300 mots sur la propagation des ondes HF en bande 40m
```

Puis dans un autre terminal :

```
ollama ps
```

Doit afficher 100% GPU.

8. Résultats mesurés et benchmarks

8.1. Configuration A — Geekom A7 Max (RDNA3)

Configuration	CPU pur	Vulkan + FA ON	Vulkan + FA OFF
eval rate	8,31 t/s	10,16 t/s	10,02 t/s
prompt eval rate	28,68 t/s	20,23 t/s	121,41 t/s

8.2. Configuration B — LX15 Pro (Vega 8)

Modèle	Taille	eval rate	prompt eval rate
mistral-nemo:12b	7,1 Go	7,08 t/s	38,12 t/s
qwen2.5:7b (long prompt)	4,7 Go	6,73 t/s	741,10 t/s

9. Allocation BIOS de VRAM dédiée — recommandations par architecture

Section nouvelle (v4) : Cette section présente un retour d'expérience original obtenu sur APU Vega 8. Contrairement à l'intuition générale ("plus de VRAM dédiée = meilleures performances LLM"), nos mesures montrent qu'allouer manuellement de la VRAM dédiée dans le BIOS sur cette architecture DÉGRADE les performances de l'inférence Ollama. Lire attentivement avant toute modification BIOS.

9.1. Contexte de l'expérimentation

Sur le LX15 Pro (Ryzen 7 5825U + Vega 8), le BIOS Aptio AMI permet l'accès à l'onglet Advanced et donc à l'option UMA Frame Buffer Size. Cela autorise à passer de l'allocation Auto (0,48 Go par défaut) à une allocation manuelle (UMA_SPECIFIED) jusqu'à 16 Go.

Nous avons donc testé trois configurations BIOS sur ce mini-PC, à conditions strictement identiques par ailleurs (Vulkan activé, Flash Attention désactivé, KV cache Q8, prompt de référence identique, modèle Mistral Nemo 12B Q4_K_M).

9.2. Résultats des trois configurations testées

Config BIOS / contexte	VRAM dédiée	SIZE chargé	eval rate	prompt eval
Auto + ctx 8192	0,48 Go	8,6 Go	7,08 t/s	38,12 t/s
UMA_SPECIFIED 8G + ctx 32768	8,0 Go	14 Go	5,09 t/s	17,14 t/s
UMA_SPECIFIED 8G + ctx 8192	8,0 Go	8,6 Go	5,08 t/s	38,87 t/s

9.3. Analyse des résultats

Constatation principale : à conditions strictement identiques (contexte 8192, même modèle, même prompt), l'allocation manuelle UMA_SPECIFIED 8G fait CHUTER la vitesse de génération de 7,08 à 5,08 t/s, soit une dégradation de 28 %. Le prompt eval rate reste identique (38 t/s), donc le ralentissement concerne uniquement la phase de génération token par token.

9.4. Hypothèse explicative

Sur un APU avec mémoire unifiée DDR4, la "VRAM dédiée" n'est pas une vraie VRAM séparée : c'est une portion réservée de la RAM système. Sur architecture Vega (GCN 5.1) :

- En mode Auto : la mémoire est gérée dynamiquement par le contrôleur, sans frontière rigide. Vulkan utilise la mémoire partagée intelligemment, en exploitant pleinement la bande passante dual-channel DDR4-3200.
- En mode UMA_SPECIFIED : 8 Go sont physiquement réservés au GPU dans une zone isolée. Cette ségrégation crée des transferts mémoire moins efficaces : le KV cache (qui est mis à jour à chaque token) peut nécessiter des mouvements entre zones dédiée et partagée, ajoutant de la latence.
- Sur RDNA3 (Ryzen 7000HS et plus récents), cette ségrégation est mieux gérée par le contrôleur mémoire amélioré et par la bande passante DDR5 plus élevée — l'allocation dédiée y est neutre voire bénéfique.

9.5. Recommandations différenciées par architecture

Architecture iGPU	Réglage BIOS recommandé	Justification
Vega 7 / Vega 8 (Ryzen 5000U)	Auto	L'allocation manuelle dégrade les performances de 28 %. Le contrôleur mémoire Vega gère mieux dynamiquement.
RDNA 2 (Ryzen 6000H)	Auto ou 4G	Pas de mesure en propre. Tester les deux et benchmarker.
RDNA 3 (Ryzen 7000HS / 8040HS)	Auto (par défaut)	Le mode Auto alloue déjà 3-4 Go automatiquement, suffisant pour Mistral Nemo 12B. Modification BIOS non nécessaire dans la plupart des cas.
RDNA 3 (BIOS bridé)	Auto imposé	Cas du Geekom A7 Max : pas d'accès Advanced, mais 3,9 Go alloués automatiquement, parfaitement suffisant.
RDNA 3.5 (Ryzen AI 300)	Auto ou 8G+	Architecture moderne, gestion mémoire avancée. Tester si le BIOS le permet, mais peu d'intérêt en pratique.

9.6. Mise en garde générale

AVERTISSEMENT IMPORTANT : Avant toute modification BIOS visant à "améliorer" les performances LLM sur un APU AMD, IMPÉRATIVEMENT effectuer un benchmark de référence (Mistral Nemo 12B, prompt standardisé, mesure eval rate et prompt eval rate). Sans cette mesure de référence, il est impossible de savoir si la modification apporte un gain ou une régression. Sur Vega 7/8 spécifiquement, le mode Auto reste optimal et toute modification UMA_SPECIFIED est déconseillée.

9.7. Procédure de retour en arrière (Vega 7/8)

Si une modification BIOS a déjà été appliquée et qu'une régression est constatée, la procédure de retour en mode Auto est la suivante :

1. Redémarrer le mini-PC, taper Suppr au boot pour entrer dans le BIOS.
2. Advanced → AMD CBS → NBIO Common Options → GFX Configuration.
3. Sur iGPU Configuration : changer UMA_SPECIFIED en Auto.
4. F10 → Yes → le mini-PC redémarre.
5. Vérifier sous Windows que la VRAM dédiée est revenue à sa valeur d'origine :

```
Get-CimInstance Win32_VideoController | Where-Object { $_.Name -match 'Radeon|AMD' } | ForEach-Object { Write-Host "$($_.Name) - VRAM : $([math]::Round($_.AdapterRAM / 1GB, 2)) Go" }
```

10. Résolution des erreurs d'allocation mémoire

10.1. Symptômes

```
Error: 500 Internal Server Error: llama runner process has terminated:
failed to allocate compute pp buffers
```

10.2. Solutions par paliers

Palier 1 : réduire OLLAMA_CONTEXT_LENGTH (32768 → 8192 → 4096 → 2048)

Palier 2 : réduire OLLAMA_NUM_BATCH (512 → 256 → 128)

Palier 3 : désactiver OLLAMA_KV_CACHE_TYPE=q8_0 (retour F16 standard)

Palier 4 : passer à un modèle plus petit (qwen2.5:7b au lieu de mistral-nemo:12b)

Important : Sur Vega 7/8 (Ryzen 5000U), NE PAS chercher à "augmenter la VRAM dédiée dans le BIOS" comme solution à un problème d'allocation. Voir section 9 : sur cette architecture, l'allocation manuelle dégrade les performances. Privilégier les paliers 1 à 4 (configuration logicielle) qui sont efficaces et n'ont pas d'effet secondaire négatif.

11. Choix du modèle LLM selon l'usage et le matériel

11.1. Recommandations par architecture iGPU

Matériel	Usage interactif	Usage RAG / long prompt
Ryzen 5000U (Vega 7/8)	qwen2.5:7b	qwen2.5:7b (prompt eval ~741 t/s)
Ryzen 7000/8000HS (RDNA3)	mistral-nemo:12b	mistral-nemo:12b
Ryzen AI 300 (RDNA3.5)	qwen2.5:14b	qwen2.5:14b ou modèles 32B

11.2. Benchmarks réels via IABrain sur LX15 Pro (Vega 8)

Les benchmarks effectués via ollama run --verbose mesurent la performance pure du modèle. En usage réel via une interface comme IABrain, OpenWebUI, Continue ou Cherry Studio, il faut prévoir un overhead de 15 à 30 % lié au prompt système, à l'historique de conversation et à la surcharge HTTP du protocole REST.

Mesures comparatives effectuées sur LX15 Pro (Ryzen 7 5825U + Vega 8) via IABrain v1.41.4 avec le prompt de référence "Écris un texte de 300 mots sur la propagation des ondes HF en bande 40 mètres"

Modèle	Taille disque	Tokens	Durée	eval rate	Qualité texte
mistral-nemo:12b	7,1 Go	478	194 s	3,9 t/s	★★★★ Très bon
qwen2.5:7b	4,7 Go	458	78 s	7,8 t/s	★★★★★ Excellent
llama3.2:3b	2,0 Go	430	36,5 s	16,9 t/s	★★ Erreurs techniques

11.3. Analyse qualité — la vitesse n'est pas tout

Le gain en vitesse des modèles plus petits se fait au prix d'une qualité technique moindre. Cette dégradation est particulièrement visible sur les sujets spécialisés comme la radio, la météorologie ou le droit.

Mistral Nemo 12B : français impeccable, structure soignée, informations techniques correctes (réflexion ionosphérique, activité solaire, propagation longue distance). Style un peu scolaire mais utilisable directement dans un document ADRASEC après relecture rapide.

Qwen 2.5 7B : français très propre, le plus précis techniquement parmi les trois modèles testés. Mention explicite des couches D et E de l'ionosphère, des cycles solaires, des phases de propagation. Excellent compromis pour la rédaction ADRASEC quotidienne.

Llama 3.2 3B : français approximatif avec quelques fautes ("deurgence", "ondesHF", "le plus chargés"). Plus problématique : plusieurs erreurs techniques notables ("voyage le long des lignes magnétiques terrestres" — faux, "les ondes HF sont les plus fortes le matin et le soir car les ions sont les plus chargés" — inverse de la réalité). Inutilisable en l'état pour un document officiel ADRASEC sans réécriture complète.

Avertissement important sur les modèles $\leq 3B$ parameters : Les modèles de moins de 3 milliards de paramètres (Llama 3.2 3B, Phi-3 mini, Qwen 2.5 3B, etc.) sont 2 à 3 fois plus rapides mais hallucinent significativement plus sur les sujets techniques spécialisés (radio, météorologie, droit, médecine). Ils peuvent inverser des notions, inventer des termes plausibles mais faux, ou propager des erreurs factuelles. À utiliser uniquement pour des tâches simples ou avec relecture humaine systématique. Ne JAMAIS utiliser pour la rédaction de documents officiels ADRASEC sans vérification approfondie d'un opérateur expérimenté.

11.4. Stratégie multi-modèles recommandée

La variable OLLAMA_MAX_LOADED_MODELS=2 permet de garder deux modèles simultanément chargés en mémoire. Sur un mini-PC avec 32 Go de RAM, on peut exploiter cette capacité pour combiner vitesse et qualité selon le besoin.

11.4.1. Configuration LX15 Pro (Vega 8) — usage opérationnel mixte

Modèle	Statut	Cas d'usage
qwen2.5:7b	Toujours chargé (défaut)	Rédaction quotidienne, RAG, chat technique, scénarios courts
llama3.2:3b	Chargé en parallèle	Classification, extraction d'entités, résumés, brouillons rapides à relire
mistral-nemo:12b	Chargé à la demande	Documents officiels ADRASEC complets, scénarios d'exercice, RETEX détaillés

Empreinte mémoire totale avec Qwen 7B + Llama 3B chargés simultanément : ~7 Go de VRAM, parfaitement compatible avec les 15-20 Go disponibles sur ton iGPU.

11.4.2. Configuration A7 Max (RDNA3) — performance maximale

Modèle	Statut	Cas d'usage
mistral-nemo:12b	Toujours chargé (défaut)	Toutes les tâches courantes — la performance RDNA3 permet d'utiliser le 12B sans compromis

qwen2.5-coder:14b	Chargé à la demande	Assistance code Python (scripts TCQ, APRS, parseurs CoT, etc.)
nomic-embed-text	Chargé à la demande	Indexation vectorielle pour RAG sur corpus documentaire FNRASEC

11.5. Différence CLI vs interface graphique (overhead IAbrian)

Pour les opérateurs ADRASEC qui comparent leurs résultats à des benchmarks publiés en ligne ou à ceux de ce document, attention à la méthode de mesure :

- Benchmark CLI (ollama run --verbose) : mesure la performance pure du modèle sans prompt système ni historique. C'est la valeur de référence "moteur".
- Usage réel via IAbrian : ajoute un prompt système (instructions de comportement), l'historique de conversation, et la surcharge HTTP du protocole REST. Overhead typique : -15 à -30 % sur l'eval rate.
- Exemple mesuré sur LX15 Pro : Mistral Nemo 12B donne 7,1 t/s en CLI vs 3,9 t/s en IAbrian (-45 %, overhead amplifié par historique long).
- Conséquence : pour estimer l'expérience utilisateur réelle, prendre le benchmark CLI et appliquer -20 à -30 %.

Recommandation méthodologique : Pour mesurer la vraie expérience opérationnelle ADRASEC, effectuer les benchmarks via l'interface réellement utilisée (IAbrian, Open WebUI, etc.) plutôt qu'en CLI. Les chiffres seront plus modestes mais plus représentatifs de ce que les opérateurs constatent au quotidien.

12. Mise à jour et maintenance d'Ollama

12.1. Vérifier la version actuelle

```
ollama --version
```

12.2. Méthodes de mise à jour

Méthode A — Auto-update intégré : clic droit sur l'icône Ollama dans la zone de notification. Si une mise à jour est disponible, l'option « Restart to update » apparaît. Variables et modèles conservés.

Méthode B — Réinstallation manuelle : télécharger depuis <https://ollama.com/download/windows> et exécuter l'installateur par-dessus la version existante.

Méthode C — Via Winget :

```
winget upgrade Ollama.Ollama
```

12.3. Mise à jour des modèles

```
ollama pull mistral-nemo:12b
ollama list
```

12.4. Maintenance périodique

- Hebdomadaire : vérifier la disponibilité d'une mise à jour Ollama

- Mensuel : ollama pull sur chaque modèle utilisé
- Trimestriel : benchmark de référence et notation dans journal de maintenance
- Semestriel : mise à jour des drivers AMD Adrenalin

13. Faut-il passer de 32 à 64 Go de DDR4/DDR5 ?

Réponse négative pour un usage ADRASEC standard, validée sur les deux configurations testées.

- Mistral Nemo 12B en Q4_K_M occupe environ 7-8 Go ; avec KV cache 8k Q8, total ~9 Go.
- Avec Vulkan, l'iGPU dispose de 15-20 Go de VRAM exploitable sur machine 32 Go.
- La vitesse d'inférence est limitée par la bande passante mémoire, pas la capacité.

Recommandation : Garder 32 Go. Investir l'écart de prix dans un mini-PC RDNA3 plutôt que dans plus de RAM sur une génération antérieure (Ryzen 5000U + 64 Go DDR4 sera moins performant qu'un Ryzen 7940HS + 32 Go DDR5).

14. To-do list récapitulative

14.1. Prérequis

1. Mini-PC AMD Ryzen avec iGPU Radeon.
2. Windows 10 ou 11, drivers AMD Adrenalin à jour.
3. Ollama 0.22 ou supérieur installé.
4. Modèle LLM téléchargé selon recommandations section 11.

14.2. Diagnostic initial

1. Identifier le CPU/iGPU et la VRAM dédiée par défaut.
2. Mesurer eval rate en CPU pur comme référence.
3. Confirmer OLLAMA_VULKAN:false dans les logs.

14.3. Application

1. Exécuter Configure-OllamaAMD.ps1 en PowerShell admin.
2. Suivre les invites du script (redémarrage Ollama automatisé).

14.4. Validation

1. Vérifier dans les logs : library=Vulkan + name="AMD Radeon..."
2. Confirmer 100% GPU via ollama ps.
3. Mesurer eval rate et comparer aux valeurs CPU pur.

14.5. Avant toute modification BIOS

1. LIRE LA SECTION 9 du présent document.
2. Identifier précisément l'architecture iGPU (Vega vs RDNA).

3. Sur Vega 7/8 : NE PAS modifier UMA Frame Buffer Size, laisser en Auto.
4. Sur RDNA2/3 : benchmarker AVANT modification pour avoir une référence comparative.

15. Conseils pour le déploiement en ADRASEC

15.1. Sécurité réseau

- Limiter l'exposition d'Ollama au réseau ADRASEC interne uniquement.
- Reverse proxy avec authentification pour accès distant.
- Configurer OLLAMA_API_KEY pour authentification simple.

15.2. Bonnes pratiques

- Toujours vérifier le contenu généré avant intégration dans un document officiel.
- Mentionner « contenu généré par IA, relu et validé par l'opérateur ».
- Conserver les mentions « EXERCICE - EXERCICE - EXERCICE » et « FICTIF - FICTIF - FICTIF » sur documents d'exercice.

15.3. Limites à connaître

- Les iGPU AMD restent 10-30× plus lents que GPU NVIDIA dédié.
- Les modèles 70B impraticables sur iGPU (< 3 t/s).
- Pour les besoins de modèles très capables, Claude et ChatGPT restent supérieurs — le LLM local complète mais ne remplace pas.

Document rédigé en retour d'expérience par F1GBD

ADRASEC 77 — Seine-et-Marne / FNRASEC

Version 4.1 — Avec benchmarks LAbraIn et stratégie multi-modèles — Mai 2026

Document libre de diffusion au sein du réseau ADRASEC / FNRASEC