

OPTIMISATION D'UN SERVEUR OLLAMA LOCAL pour IAbrain

sur mini-PC AMD Ryzen avec iGPU Radeon



Guide pratique, scripts d'automatisation et benchmarks

Version 3 — Avec script PowerShell autonome et maintenance

Nouveautés version 3 : Cette version ajoute deux compléments pratiques par rapport à la v2 : une section dédiée à la mise à jour et maintenance d'Ollama (passage de version, sauvegarde, points de contrôle), et un script PowerShell autonome (Configure-OllamaAMD.ps1) prêt à télécharger et exécuter, qui automatise la totalité de la configuration en un seul fichier.

Contexte d'usage ADRASEC : Mise en service d'un serveur LLM local (Ollama) sur mini-PC pour assister la rédaction de scénarios d'exercice, de RETEX, de documents FNRASEC, et l'analyse de logs ou de traces radio. Le présent document décrit la procédure d'optimisation permettant de passer d'une exécution CPU pure (lente) à une exécution GPU via Vulkan, sans achat de matériel supplémentaire.

Sommaire

- 1. Choix du matériel selon l'architecture iGPU
- 2. Configurations de référence testées
- 3. Problème constaté et diagnostic
- 4. Procédure d'optimisation — méthode interface graphique
- 5. Procédure d'optimisation — script PowerShell tout-en-un
- 6. Script PowerShell autonome (.ps1) clé en main
- 7. Vérification du fonctionnement
- 8. Résultats mesurés et benchmarks
- 9. Résolution des erreurs d'allocation mémoire
- 10. Choix du modèle LLM selon l'usage et le matériel
- 11. Mise à jour et maintenance d'Ollama
- 12. Faut-il passer de 32 à 64 Go de DDR4/DDR5 ?
- 13. To-do list récapitulative
- 14. Conseils pour le déploiement en ADRASEC

1. Choix du matériel selon l'architecture iGPU

Avant toute mise en service d'un serveur Ollama local, il est essentiel d'identifier précisément l'architecture iGPU du mini-PC ciblé. Tous les processeurs AMD Ryzen mobiles ne sont pas équivalents pour l'inférence LLM, et l'écart de performance entre deux générations peut être de l'ordre de 2 à 3 fois.

1.1. Tableau comparatif des iGPU AMD

Génération CPU	Architecture iGPU	Exemples iGPU	RAM type	Perf LLM relative
Ryzen 5000U (2021)	Vega 7 / Vega 8	Radeon Graphics	DDR4-3200	× 1 (base)
Ryzen 6000H (2022)	RDNA 2	Radeon 660M, 680M	DDR5-4800	× 1,8
Ryzen 7000HS (2023)	RDNA 3	Radeon 760M, 780M	DDR5-5600	× 2,5
Ryzen 8040HS (2024)	RDNA 3 + NPU	Radeon 780M, 880M	DDR5-5600	× 2,5-3
Ryzen AI 300 (2024)	RDNA 3.5 + NPU XDNA2	Radeon 880M, 890M	LPDDR5X-7500	× 3-4

1.2. Recommandation pour un serveur ADRASEC

Pour un serveur Ollama destiné à être partagé sur le réseau ADRASEC local, le matériel le plus pertinent en rapport performance / prix / consommation est un mini-PC à base de :

- Ryzen 7000HS / 7040HS / 7940HS (Radeon 780M, DDR5) — meilleur compromis sur le marché de l'occasion 2026
- Ryzen 8845HS / 8945HS (Radeon 780M + NPU) — équivalent aux 7000HS avec NPU dédié
- Ryzen AI 9 HX 370 / 9 365 (Radeon 880M / 890M) — pour les déploiements neufs haut de gamme

Les mini-PC à base de Ryzen 5000U restent utilisables (voir résultats LX15 Pro plus loin) mais avec des modèles plus petits (7B) et des performances limitées (~7 tokens/s en génération). Acceptable pour un usage non interactif (rédaction asynchrone, batch de RETEX), frustrant en chat temps réel.

2. Configurations de référence testées

2.1. Configuration A — Geekom A7 Max (RDNA3 moderne)

Élément	Détail
Modèle mini-PC	Geekom A7 Max
Processeur	AMD Ryzen 9 7940HS (8C/16T, Zen 4)
iGPU	AMD Radeon 780M (RDNA 3, 12 CU, gfx1103)
Mémoire vive	32 Go DDR5-4800 (2×16 Go, dual channel)
VRAM dédiée (BIOS)	3,9 Go (allocation automatique)

2.2. Configuration B — LX15 Pro (Vega 8, génération précédente)

Élément	Détail
Modèle mini-PC	LX15 Pro
Processeur	AMD Ryzen 7 5825U (8C/16T, Zen 3+)
iGPU	AMD Radeon Vega 8 (GCN 5.1, 8 CU)
Mémoire vive	32 Go DDR4-3200 (2×16 Go, dual channel)
VRAM dédiée (BIOS)	0,48 Go (allocation minimale)

3. Problème constaté et diagnostic

À l'installation par défaut sous Windows, Ollama ne détecte pas correctement les iGPU AMD Radeon (toutes générations confondues). Sans intervention, le serveur tourne en mode 100 % CPU.

3.1. Diagnostic en 4 commandes

Vérifier la version d'Ollama (0.22+ requise pour Vulkan natif) :

```
ollama --version
```

Mesurer la vitesse en CPU pur :

```
ollama run mistral-nemo:12b --verbose
>>> Écris un texte de 300 mots sur la propagation des ondes HF en bande 40 mètres
```

Confirmer que le modèle est en CPU :

```
ollama ps
```

Consulter les logs Ollama :

```
Get-Content "$env:LOCALAPPDATA\Ollama\server.log" -Tail 100 | Select-String
"VULKAN|compute|library"
```

4. Procédure d'optimisation — méthode interface graphique

Cette méthode utilise les paramètres Windows. Plus longue mais visuelle. Pour une application en une seule commande, voir section 5 (PowerShell) ou section 6 (script autonome).

4.1. Activer Vulkan dans Ollama

1. Touche Windows → taper « variables d'environnement » → ouvrir « Modifier les variables d'environnement pour votre compte ».
2. Section « Variables utilisateur » → bouton « Nouvelle... ».
3. Nom = OLLAMA_VULKAN, Valeur = 1, OK.

4.2. Supprimer les variables ROCm parasites

1. Rechercher HSA_OVERRIDE_GFX_VERSION dans Variables utilisateur ET Variables système.
2. Si elle existe, la sélectionner et cliquer sur « Supprimer ».

4.3. Désactiver Flash Attention (critique pour Vulkan AMD)

1. Section « Variables système » (partie basse) → bouton « Nouvelle... ».
2. Nom = OLLAMA_FLASH_ATTENTION, Valeur = 0, OK.

4.4. Variables système complémentaires recommandées

Nom	Valeur	Rôle
OLLAMA_HOST	http://0.0.0.0:11434	Expose le serveur sur le LAN
OLLAMA_KEEP_ALIVE	30m	Maintien du modèle 30 min en mémoire
OLLAMA_MAX_LOADED_MODELS	2	Permet 2 modèles simultanés en RAM
OLLAMA_KV_CACHE_TYPE	q8_0	KV cache quantifié, économise la VRAM
OLLAMA_NUM_PARALLEL	1	Une requête à la fois (économise VRAM)
OLLAMA_CONTEXT_LENGTH	8192	Contexte par défaut (voir section 9)
OLLAMA_NUM_BATCH	256	Batch réduit pour économiser VRAM

5. Procédure d'optimisation — script PowerShell tout-en-un

Méthode rapide pour appliquer l'ensemble de la configuration en une seule commande à copier-coller dans PowerShell admin. Pour une solution encore plus pratique sous forme de fichier autonome téléchargeable, voir section 6.

5.1. Prérequis

- Menu Démarrer → taper « powershell » → clic droit → « Exécuter en tant qu'administrateur »
- Le titre de la fenêtre doit indiquer « Administrateur : Windows PowerShell »

5.2. Script d'application

Copier-coller le bloc complet ci-dessous dans PowerShell admin :

```
# === Configuration Ollama optimisée pour iGPU AMD Radeon ===
# F1GBD / ADRASEC 77 – Vulkan + paramètres serveur

# Variables UTILISATEUR (activation Vulkan)
[System.Environment]::SetEnvironmentVariable('OLLAMA_VULKAN', '1', 'User')
[System.Environment]::SetEnvironmentVariable('HSA_OVERRIDE_GFX_VERSION', $null, 'User')

# Variables SYSTÈME (configuration serveur)
[System.Environment]::SetEnvironmentVariable('OLLAMA_FLASH_ATTENTION', '0', 'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_KV_CACHE_TYPE', 'q8_0', 'Machine')
```

```
[System.Environment]::SetEnvironmentVariable('OLLAMA_KEEP_ALIVE', '30m',
'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_MAX_LOADED_MODELS', '2',
'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_HOST',
'http://0.0.0.0:11434', 'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_NUM_PARALLEL', '1',
'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_CONTEXT_LENGTH', '8192',
'Machine')
[System.Environment]::SetEnvironmentVariable('OLLAMA_NUM_BATCH', '256', 'Machine')

Write-Host "Configuration terminée. Redémarrer Ollama." -ForegroundColor Green
```

6. Script PowerShell autonome (.ps1) clé en main

Pour un déploiement homogène sur plusieurs postes ADRASEC, ou pour un opérateur préférant exécuter un fichier plutôt que copier-coller des commandes, un script PowerShell autonome est mis à disposition : Configure-OllamaAMD.ps1.

6.1. Fonctionnalités du script

Le script effectue automatiquement :

- Vérification des droits administrateur (refuse de s'exécuter sinon)
- Détection automatique du matériel (CPU, RAM, iGPU, VRAM dédiée)
- Recommandation automatique des paramètres selon la VRAM détectée
- Affichage de la configuration actuelle avant modification
- Application de toutes les variables d'environnement nécessaires
- Vérification après application avec affichage des valeurs définies
- Proposition d'arrêt et redémarrage d'Ollama de manière automatisée
- Test des performances après redémarrage

6.2. Modes d'exécution

Le script accepte 4 modes via le paramètre -Action :

Mode	Description
Apply (défaut)	Applique la configuration optimale. Mode utilisé si aucun paramètre n'est spécifié.
Check	Affiche la configuration actuelle sans modification (audit). Utile pour vérifier l'état d'un poste avant intervention.
Restore	Restaure la configuration Ollama par défaut. Supprime toutes les variables ajoutées par le script.
Bench	Lance un test de performance après application (nécessite qu'Ollama soit en cours d'exécution).

6.3. Utilisation

Étape 1 — Télécharger le script

Le fichier Configure-OllamaAMD.ps1 est diffusé en pièce jointe à ce document. Il peut également être copié-collé manuellement depuis le code source disponible en annexe.

Le placer dans un dossier de travail, par exemple :

```
C:\ADRASEC\Configure-OllamaAMD.ps1
```

Étape 2 — Autoriser l'exécution de scripts PowerShell

Par défaut, Windows bloque l'exécution des scripts .ps1 téléchargés. Pour autoriser le script (à exécuter une seule fois, en PowerShell admin) :

```
Set-ExecutionPolicy -Scope CurrentUser -ExecutionPolicy RemoteSigned
```

Cette commande autorise les scripts locaux non signés et les scripts distants signés. Pour la session uniquement, sans modifier la politique permanente :

```
Set-ExecutionPolicy -Scope Process -ExecutionPolicy Bypass
```

Étape 3 — Débloquer le fichier (téléchargements depuis Internet uniquement)

Si le fichier provient d'un téléchargement, Windows le marque comme « zone Internet ». Pour le débloquent :

```
Unblock-File -Path C:\ADRASEC\Configure-OllamaAMD.ps1
```

Étape 4 — Lancer le script

Ouvrir PowerShell en administrateur, naviguer vers le dossier du script et l'exécuter :

```
cd C:\ADRASEC
.\Configure-OllamaAMD.ps1
```

Le script affiche une bannière, détecte le matériel, montre la configuration actuelle, applique les variables, affiche la configuration finale et propose le redémarrage automatique d'Ollama.

6.4. Exemples d'utilisation avancée

Audit d'un poste sans modification :

```
.\Configure-OllamaAMD.ps1 -Action Check
```

Configuration pour mini-PC à très faible VRAM dédiée (Vega 7/8 sans BIOS débloqué) :

```
.\Configure-OllamaAMD.ps1 -ContextLength 4096 -NumBatch 128
```

Configuration pour mini-PC RDNA3 avec VRAM dédiée 4 Go ou plus :

```
.\Configure-OllamaAMD.ps1 -ContextLength 16384 -NumBatch 512
```

Restauration complète à la configuration par défaut :

```
.\Configure-OllamaAMD.ps1 -Action Restore
```

Aide intégrée :

```
Get-Help .\Configure-OllamaAMD.ps1 -Detailed
```

6.5. Sortie typique du script

Exemple de sortie console après exécution sur un Geekom A7 Max :

```
=====
Configuration Ollama optimisee pour iGPU AMD Radeon
F1GBD / ADRASEC 77 - FNRASEC
Version 1.0 - Mai 2026
=====

--- Detection materielle ---
CPU      : AMD Ryzen 9 7940HS w/ Radeon 780M Graphics
RAM      : 31.4 Go
GPU/iGPU : AMD Radeon(TM) Graphics (VRAM dediee : 3.91 Go)

RECOMMANDATION : Bonne VRAM dediee (3.91 Go)
Defaut OK : -ContextLength 8192 -NumBatch 256

--- Application de la configuration optimisee ---
[OK] OLLAMA_VULKAN = 1 (User)
[OK] OLLAMA_FLASH_ATTENTION = 0 (Machine)
[OK] OLLAMA_KV_CACHE_TYPE = q8_0 (Machine)
...
Configuration appliquee avec succes !
```

6.6. Sécurité et confiance

Bonne pratique de sécurité : Comme pour tout script PowerShell téléchargé, il est recommandé d'ouvrir le fichier Configure-OllamaAMD.ps1 dans un éditeur de texte (Notepad++, VS Code) AVANT de l'exécuter, pour vérifier qu'il ne contient que des manipulations attendues. Le script est conçu pour être lisible : les variables modifiées sont préfixées OLLAMA_ et toutes les opérations sont commentées. Aucune connexion réseau n'est établie, aucun fichier n'est téléchargé.

7. Vérification du fonctionnement

7.1. Contrôle des logs après redémarrage

```
Get-Content "$env:LOCALAPPDATA\Ollama\server.log" -Tail 60 | Select-String
"Vulkan|library|VRAM"
```

Les lignes attendues :

```
OLLAMA_VULKAN:true
OLLAMA_FLASH_ATTENTION:false
inference compute id=... library=Vulkan name=Vulkan0
description="AMD Radeon ... Graphics" type=iGPU
```

7.2. Contrôle de la répartition CPU/GPU

```
ollama run mistral-nemo:12b
```

```
>>> Bonjour
```

Puis dans un autre terminal :

```
ollama ps
```

La colonne PROCESSOR doit afficher 100% GPU.

8. Résultats mesurés et benchmarks

8.1. Configuration A — Geekom A7 Max (RDNA3)

Configuration	CPU pur	Vulkan + FA ON	Vulkan + FA OFF
eval rate (Nemo 12B)	8,31 t/s	10,16 t/s	10,02 t/s
prompt eval rate (Nemo 12B)	28,68 t/s	20,23 t/s	121,41 t/s

8.2. Configuration B — LX15 Pro (Vega 8)

Modèle	Taille	eval rate	prompt eval rate
mistral-nemo:12b	7,1 Go	7,08 t/s	38,12 t/s
qwen2.5:7b (long prompt)	4,7 Go	6,73 t/s	741,10 t/s

9. Résolution des erreurs d'allocation mémoire

9.1. Symptômes d'une erreur d'allocation

```
Error: 500 Internal Server Error: llama runner process has terminated:
failed to allocate compute pp buffers
```

9.2. Solutions par paliers

Palier 1 : réduire OLLAMA_CONTEXT_LENGTH (32768 → 8192 → 4096 → 2048)

Palier 2 : réduire OLLAMA_NUM_BATCH (512 → 256 → 128)

Palier 3 : désactiver OLLAMA_KV_CACHE_TYPE=q8_0 (retour F16 standard)

Palier 4 : passer à un modèle plus petit (7B au lieu de 12B)

Palier 5 (solution de fond) : augmenter la VRAM dédiée dans le BIOS (UMA Frame Buffer Size = 8G)

Le script Configure-OllamaAMD.ps1 (section 6) permet d'appliquer ces paliers facilement via les paramètres -ContextLength et -NumBatch.

10. Choix du modèle LLM selon l'usage et le matériel

Matériel	Usage interactif	Usage RAG / long prompt
Ryzen 5000U (Vega 7/8)	llama3.2:3b ou qwen2.5:7b	qwen2.5:7b
Ryzen 6000H (RDNA2)	qwen2.5:7b	mistral-nemo:12b ou qwen2.5:7b
Ryzen 7000/8000HS (RDNA3)	mistral-nemo:12b	mistral-nemo:12b
Ryzen AI 300 (RDNA3.5)	mistral-nemo:12b ou qwen2.5:14b	qwen2.5:14b ou modèles 32B

11. Mise à jour et maintenance d'Ollama

Ollama évolue rapidement (versions toutes les 2-4 semaines en moyenne). Les améliorations récentes concernent particulièrement le support Vulkan pour AMD, le KV cache, le multi-modèle simultané et les nouvelles familles de modèles. Maintenir Ollama à jour permet de bénéficier de gains de performance significatifs sans rien changer à la configuration.

11.1. Pourquoi mettre à jour ?

- Améliorations Vulkan : sur AMD Radeon, chaque version récente apporte typiquement +5 à +15 % de tokens/s.
- Correctifs des erreurs d'allocation mémoire sur iGPU à faible VRAM dédiée.
- Support de nouveaux modèles (Llama 3.3, Qwen 3, Mistral nouvelles versions, etc.).
- Corrections de bugs et améliorations de stabilité du serveur.
- Nouvelles options de configuration (variables d'environnement, paramètres CLI).

11.2. Vérifier la version actuelle

```
ollama --version
```

La dernière version stable est consultable sur :

- <https://ollama.com/download/windows> (page officielle)
- <https://github.com/ollama/ollama/releases> (historique complet et notes de version)

11.3. Méthodes de mise à jour

11.3.1. Méthode A — Auto-update intégré (recommandée)

Depuis la version 0.5, Ollama Windows propose une mise à jour automatique via son icône système :

1. Clic droit sur l'icône Ollama dans la zone de notification.
2. Si une mise à jour est disponible, l'option « Restart to update » apparaît.
3. Cliquer dessus : Ollama télécharge et installe la nouvelle version.
4. Le service redémarre automatiquement avec la nouvelle version.

Avantage : ne nécessite aucune intervention manuelle, les variables d'environnement et les modèles téléchargés sont conservés.

11.3.2. Méthode B — Réinstallation manuelle

Si l'auto-update échoue ou n'est pas disponible :

1. Quitter Ollama (clic droit icône système → Quit).
2. Fermer tous les terminaux PowerShell.
3. Télécharger la dernière version depuis <https://ollama.com/download/windows>.
4. Exécuter l'installateur OllamaSetup.exe (installation « par-dessus » la version existante).
5. Relancer Ollama depuis le menu Démarrer.
6. Vérifier la nouvelle version : `ollama --version`

Les modèles téléchargés (stockés dans `C:\Users\<utilisateur>\.ollama\models`) et les variables d'environnement sont préservés.

11.3.3. Méthode C — Mise à jour via Winget

Si Ollama a été initialement installé via le gestionnaire de paquets Windows :

```
winget upgrade Ollama.Ollama
```

Lister les paquets installés ayant des mises à jour disponibles :

```
winget upgrade
```

11.4. Procédure de mise à jour sécurisée pour serveur ADRASEC

Pour un serveur en production utilisé par plusieurs opérateurs ADRASEC, suivre cette procédure pour éviter les régressions :

1. Mesurer les performances actuelles comme référence (eval rate sur prompt type ADRASEC).
2. Noter la version actuelle d'Ollama et la liste des modèles utilisés.
3. Annoncer une fenêtre de maintenance aux utilisateurs (~ 10 min).
4. Effectuer la mise à jour (méthode A ou B).
5. Vérifier la nouvelle version : `ollama --version`
6. Re-vérifier les variables d'environnement (un installateur ne devrait pas les modifier, mais contrôle de sécurité) :

```
.\Configure-OllamaAMD.ps1 -Action Check
```

7. Lancer le test de référence et comparer le eval rate à la valeur initiale.
8. En cas de régression > 20 %, désinstaller et réinstaller la version précédente (voir 11.6).

11.5. Mise à jour des modèles

Les modèles eux-mêmes (Mistral Nemo, Qwen, Llama) sont régulièrement mis à jour par leurs éditeurs. Pour récupérer la dernière version d'un modèle :

```
ollama pull mistral-nemo:12b
```

Si une nouvelle version est disponible, elle est téléchargée. Sinon, Ollama indique que le modèle est déjà à jour.

Pour lister les modèles installés avec leur date :

```
ollama list
```

Pour supprimer une ancienne version d'un modèle et libérer de l'espace :

```
ollama rm <nom_modele>
```

11.6. Retour à une version antérieure (rollback)

Si une nouvelle version d'Ollama dégrade les performances ou introduit un bug, il est possible de revenir à une version antérieure :

1. Quitter Ollama et fermer les terminaux PowerShell.
2. Aller sur <https://github.com/ollama/ollama/releases>
3. Identifier la version souhaitée et télécharger OllamaSetup.exe correspondant.
4. Désinstaller la version actuelle via Paramètres → Applications → Ollama → Désinstaller.
5. Installer la version souhaitée via OllamaSetup.exe téléchargé.
6. Réappliquer la configuration via .\Configure-OllamaAMD.ps1 si nécessaire.

Bonne pratique : Avant chaque mise à jour majeure (passage de 0.22 à 0.23 par exemple), copier le fichier d'installation actuel d'Ollama (OllamaSetup.exe de la version précédente) dans un dossier d'archives ADRASEC. Cela permet un rollback rapide en cas de problème, sans dépendre de la disponibilité du fichier sur GitHub.

11.7. Sauvegarde de la configuration

Pour conserver une copie de la configuration Ollama actuelle (utile pour déployer la même config sur un autre poste) :

```
.\Configure-OllamaAMD.ps1 -Action Check > C:\ADRASEC\config_ollama_backup.txt
```

Cette commande exporte la configuration dans un fichier texte daté, à archiver avec les autres documents ADRASEC.

11.8. Maintenance périodique recommandée

Fréquence	Action
Hebdomadaire	Vérifier la disponibilité d'une mise à jour Ollama (clic droit icône système)
Mensuel	Vérifier les mises à jour de modèles (ollama pull <modèle> pour chacun)
Trimestriel	Benchmark complet : mesurer eval rate de référence et noter dans le journal de maintenance
Trimestriel	Vérifier l'espace disque (les modèles inutilisés peuvent être supprimés)
Semestriel	Mettre à jour les drivers AMD Adrenalin Edition (depuis amd.com)
Annuel	Évaluer l'opportunité de changer de modèle LLM (nouveaux modèles plus performants)

12. Faut-il passer de 32 à 64 Go de DDR4/DDR5 ?

Question fréquente lors de l'équipement de mini-PC pour usage LLM local. La réponse, validée sur les deux configurations testées, est négative pour un usage ADRASEC standard.

- Mistral Nemo 12B en Q4_K_M occupe environ 7-8 Go ; avec KV cache 8k Q8, total ~9 Go.
- Avec Vulkan, l'iGPU dispose de 15-18 Go de VRAM exploitable sur machine 32 Go.

- La vitesse d'inférence est limitée par la bande passante mémoire, pas la capacité.

Recommandation finale : Garder 32 Go pour un usage ADRASEC standard. Investir l'écart de prix dans un mini-PC RDNA3 plutôt que dans plus de RAM sur une génération antérieure.

13. To-do list récapitulative

13.1. Prérequis

1. Mini-PC ou portable équipé d'un APU AMD Ryzen avec iGPU Radeon.
2. Windows 10 ou 11 à jour.
3. Drivers AMD Adrenalin Edition à jour.
4. Ollama version 0.22 ou supérieure installé.
5. Modèle LLM téléchargé selon recommandations section 10.

13.2. Application (3 options possibles)

Option A — Script .ps1 autonome (le plus simple, recommandé) :

1. Télécharger Configure-OllamaAMD.ps1 et le placer dans C:\ADRASEC\
2. Autoriser l'exécution : Set-ExecutionPolicy -Scope CurrentUser RemoteSigned
3. Lancer en PowerShell admin : .\Configure-OllamaAMD.ps1
4. Suivre les invites du script (qui propose le redémarrage Ollama).

Option B — Bloc PowerShell copier-coller :

1. Ouvrir PowerShell en administrateur.
2. Copier-coller le bloc de la section 5.2.
3. Redémarrer Ollama manuellement.

Option C — Interface graphique :

1. Suivre la procédure de la section 4 (variables une par une).

13.3. Validation

1. Contrôler dans les logs : library=Vulkan
2. Charger un modèle et confirmer 100% GPU via ollama ps.
3. Mesurer eval rate et prompt eval rate.

14. Conseils pour le déploiement en ADRASEC

14.1. Sécurité réseau

- Limiter l'exposition d'Ollama au réseau ADRASEC interne uniquement.
- Utiliser un reverse proxy avec authentification basique pour accès distant.
- Configurer OLLAMA_API_KEY pour activer l'authentification simple.
- Surveiller les logs d'accès dans server.log.

14.2. Bonnes pratiques d'utilisation

- Toujours vérifier le contenu généré avant intégration dans un document officiel ADRASEC.
- Conserver la mention « contenu généré par assistant IA, relu et validé par l'opérateur ».
- Ne jamais utiliser le LLM pour produire du contenu opérationnel en temps réel sans relecture.
- Pour les exercices, conserver les mentions « EXERCICE - EXERCICE - EXERCICE » et « FICTIF - FICTIF ».

14.3. Limites à connaître

- L'inférence sur iGPU AMD reste 10-30× plus lente que sur GPU NVIDIA dédié.
 - Les modèles 70B sont inutilisables en pratique sur iGPU (< 3 t/s).
 - Pour les besoins ponctuels de modèles très capables, Claude ou ChatGPT restent supérieurs — un LLM local complète mais ne remplace pas totalement les services cloud.
 - Consommation électrique modeste : 15-25 W au repos, 45-65 W en inférence — adapté à H24.
-

Document rédigé en retour d'expérience par F1GBD

ADRASEC 77 — Seine-et-Marne / FNRASEC

Version 3.0 — Avec script PowerShell autonome et maintenance — Mai 2026

Document et script libres de diffusion au sein du réseau ADRASEC / FNRASEC