

FICHE TECHNIQUE

Configurations recommandées

XERULITH en simulation avec Arma 3, IA Ollama en local ou dans le cloud

Configurations minimale et optimale · Mémoire graphique à prévoir · Modèles d'IA (LLM) recommandés · Réglages d'Ollama, d'Arma 3 et de XERULITH

Arma 3 et l'IA locale se partagent la carte graphique : c'est elle qui décide de la configuration.

Trois charges sur le poste de simulation

1 ARMA 3

Le simulateur (Steam, mod Pythia, pont @XerulithBridge)

Charge surtout le **processeur** (IA d'Arma, physique) et la **carte graphique**. Il tourne en fenêtre, **visible** : XERULITH capture l'image de sa fenêtre (15 images/s). Lancé avec `-noPause`, BattlEye désactivé.

2 OLLAMA

Le pilote IA : modèle de décision et modèle de vision

En **local**, les modèles doivent tenir dans la **mémoire graphique (VRAM)** pour répondre vite ; s'ils débordent, Ollama passe une partie sur le processeur et chaque cycle devient beaucoup plus lent. En **cloud**, le calcul est fait chez Ollama (ollama.com) : seule la connexion Internet compte.

3 XERULITH

Le poste de pilotage (XERULITH.exe)

Léger : interface, capture vidéo, garde-fous, carte, journal. Quelques centaines de Mo de mémoire. Windows 10 ou 11, 64 bits.

Trois architectures possibles

🖥️ A · Tout sur un PC

Arma 3, XERULITH et Ollama sur le **même PC**.

Simple et autonome, mais Arma et l'IA se disputent la **VRAM** : carte graphique de 16 à 24 Go conseillée.

🖧 B · Deux PC en réseau

PC de simulation (Arma 3 + XERULITH) et **serveur Ollama** sur le réseau local.

La meilleure solution : chaque machine garde sa carte graphique, **sans Internet**.

☁️ C · Ollama Cloud

Arma 3 + XERULITH sur le PC, IA **sur ollama.com** (clé API).

Aucune carte graphique pour l'IA, de gros modèles ; mais **Internet obligatoire**, latence et images envoyées hors du réseau.

16 Go	24 Go	2	0
VRAM : PC unique, IA locale	VRAM : serveur IA optimal	modèles : décision + vision	carte IA en mode cloud

Repères : les tailles de modèles et les besoins en mémoire sont ceux publiés pour Ollama (quantification standard, contexte de 8 000 jetons). Les besoins réels varient avec les réglages graphiques d'Arma, la longueur du contexte et la version des modèles : **vérifiez avec le Gestionnaire des tâches** (Performances → GPU → mémoire dédiée) pendant un premier essai.

Configurations minimale et optimale

Les colonnes « locale » supposent l'architecture **A** pour la minimale et **B** (ou un PC unique à 24 Go de VRAM) pour l'optimale. Les colonnes « cloud » supposent l'architecture **C**.

	Locale MINIMALE	Locale OPTIMALE	Cloud MINIMALE	Cloud OPTIMALE
Système	Windows 10/11 64 bits	Windows 10/11 64 bits (PC de simulation) ; serveur Ollama Windows ou Linux	Windows 10/11 64 bits	Windows 10/11 64 bits
Processeur	6 cœurs récents (Ryzen 5 / Core i5 de 2020 et après)	8 cœurs à fréquence élevée (Ryzen 7 / Core i7 récents) : l'IA d'Arma en profite	4 cœurs (minimum d'Arma 3) ; 6 conseillés	8 cœurs à fréquence élevée
Mémoire vive	32 Go	32 Go (simulation) + 64 Go (serveur IA)	16 Go	32 Go
Carte graphique	**12 Go de VRAM** (ex. RTX 3060 12 Go) : un seul modèle d'IA, Arma en réglages bas	Simulation : 8 à 12 Go (ex. RTX 4070) ; serveur IA : **24 Go** (ex. RTX 3090 / 4090) ; ou un PC unique à 24 Go	6 Go (recommandé d'Arma 3 : GTX 1060 / RX 580)	8 à 12 Go : Arma en réglages élevés
Stockage	SSD, 120 Go libres (Arma 3 ≈ 80 Go + modèles ≈ 10 Go)	SSD NVMe ; serveur : 100 Go pour plusieurs modèles	SSD, 100 Go libres	SSD NVMe, 100 Go libres
Écrans	1 (Arma et XERULITH côte à côte)	**2** : Arma sur l'un, XERULITH sur l'autre	1	2
Réseau	Aucun (tout en local)	Ethernet gigabit entre les deux PC ; aucun Internet	Internet stable, envoi ≥ 5 Mbit/s	Fibre, envoi ≥ 20 Mbit/s, faible latence
Modèles d'IA	`gemma3:12b` seul, décision **et** vision (case « Joindre le panorama »)	`gemma3:12b` (décision) + `qwen3-vl:8b` (vision) chargés ensemble ; ou `gemma3:27b` / `gemma4:31b`	`gemma4:31b` (cloud) : décision et vision	`gemma4:31b` ; alternatives avec vision : `mistral-large-4`, `kimi-k2.6`
Abonnement	—	—	Ollama **Free** (modèles de départ, 1 requête à la fois)	Ollama **Pro** (3 requêtes simultanées) ou Max
Réactivité	Correcte si tout tient en VRAM ; lente sinon	**La meilleure** : modèles toujours chargés	Dépend du réseau et de la file d'attente	Bonne ; quotas mensuels à surveiller
Hors réseau	**Oui**	**Oui**	Non	Non
Confidentialité	Totale (rien ne sort)	Totale (réseau local)	Images et textes envoyés à ollama.com	Idem ; « jamais journalisés ni utilisés pour l'entraînement » selon Ollama

Budget de mémoire graphique d'un PC unique (architecture A)

Charge	VRAM indicative	Remarque
Arma 3, 1920 × 1080, réglages moyens	3 à 5 Go	Plus avec la distance de vue et les textures élevées
`gemma3:12b` (décision, et vision s'il voit le panorama)	≈ 8 Go + contexte	Téléchargement de 8,1 Go : c'est le plancher une fois chargé
`qwen3-vl:8b` (vision)	≈ 6 Go + contexte	Téléchargement de 6,1 Go ; tient sur une carte de 8 Go seul
Contexte (cache) des deux modèles	1 à 2 Go	À 8 000 jetons ; bien plus à 32 000 jetons
Total avec deux modèles	**≈ 18 à 21 Go**	→ carte de **24 Go**, ou un seul modèle sur 12 à 16 Go, ou serveur Ollama séparé

Modèles d'IA (LLM) recommandés

XERULITH utilise **deux rôles** : le **modèle de décision** (il lit l'observation et donne la PENSÉE et les directives) et le **modèle de vision** (il décrit le panorama de la caméra). Un modèle **multimodal** (qui voit les images) peut tenir les deux rôles avec la case **« Joindre le panorama au modèle de décision »**.

En local (Ollama sur le PC ou sur un serveur du réseau)

Rôle	Modèle	Taille (Ollama)	Quand le choisir
Décision (par défaut)	`gemma3:12b`	8,1 Go	**Le meilleur compromis** : suit bien les missions longues, voit aussi les images ; carte de 12 Go et plus
Vision (par défaut)	`qwen3-vl:8b`	6,1 Go	Descriptions d'images précises (objets, textes, personnes) ; à garder chargé avec le modèle de décision
Décision, PC modeste	`gemma3:4b`	≈ 3 Go	Essais sur une carte de 6 à 8 Go ; suit moins bien les missions longues (Arma 3)
Décision, haute qualité	`gemma3:27b`	17 Go	Serveur de 24 Go : raisonnement plus sûr, missions d'exercice complètes
Décision + vision, haute qualité	`gemma4:31b`	≈ 20 Go	Serveur de 24 Go et plus ; modèle aussi proposé dans le cloud (même comportement en local et en cloud)
Mémoire de terrain	`nomic-embed-text`	274 Mo	Recherche « par le sens » dans la mémoire de terrain ; tourne même sur le processeur

Recommandation locale : PC unique de 12 à 16 Go → `gemma3:12b` seul (décision et vision) ; PC unique de 24 Go ou serveur → `gemma3:12b` + `qwen3-vl:8b` (réglage par défaut de XERULITH) ; serveur de 24 Go et plus pour la meilleure qualité → `gemma4:31b` ou `gemma3:27b` en décision. Ajoutez toujours `nomic-embed-text` pour la mémoire de terrain.

Dans le cloud (Ollama Cloud, clé API)

Rôle	Modèle cloud	Vision	Remarque
Décision + vision (par défaut)	`gemma4:31b`	oui	Choisi automatiquement par XERULITH en mode cloud ; même famille qu'en local
Alternative grande taille	`mistral-large-4`	oui	Très bon français ; plus coûteux en crédits
Alternative	`kimi-k2.6`	oui	Grand modèle multimodal ; à comparer sur vos missions
Hybride conseillé	vision en local + décision en cloud	—	Connexion **Automatique** : réseau local d'abord, cloud si aucun serveur ne répond

Le catalogue cloud évolue vite : noms relevés sur ollama.com le 20 octobre 2026. Avant une séance, cliquez **Connexion Ollama** (onglet IA) pour afficher la liste réelle, et testez le modèle en mode **Observer**. Les modèles « thinking » sont utilisables : XERULITH désactive leur raisonnement caché.

Réglages conseillés

Ollama (local)

- `OLLAMA_MAX_LOADED_MODELS=2` : décision et vision restent chargées ensemble (pas d'échange à chaque cycle).
- `OLLAMA_FLASH_ATTENTION=1` et `OLLAMA_KV_CACHE_TYPE=q8_0` : le contexte prend moins de mémoire.
- `OLLAMA_CONTEXT_LENGTH=8192` : suffisant pour XERULITH, évite de déborder de la VRAM.
- Serveur sur le réseau : `OLLAMA_HOST=0.0.0.0` et port **11434** ouvert dans le pare-feu ; redémarrer Ollama après chaque changement (`setx …`).
- Télécharger avant la séance : `ollama pull gemma3:12b`, `qwen3-vl:8b`, `nomic-embed-text`.

XERULITH

- Onglet **IA — Ollama** : connexion **Réseau local**, **Cloud Ollama** ou **Automatique** ; **⟳ Modèles** pour la liste.
- Un seul modèle multimodal : cocher **« Joindre le panorama au modèle de décision »** et laisser la vision vide.
- Raccourcis **Ctrl+Alt+X** (revenir sur XERULITH) et **Ctrl+Alt+S** (STOP) depuis Arma.

Arma 3

- Mode **fenêtré** (ou fenêtré plein écran), 1920 × 1080 ; la fenêtre doit rester **visible**, rien par-dessus.
- Paramètres du lanceur : `-noPause`, mods **@Pythia** et **@XerulithBridge** (et **@XerulithRobot** pour le robot), BattlEye désactivé.
- PC unique : qualité **moyenne**, distance de vue 2 000 à 3 000 m, ombres moyennes, images limitées à 60/s : la VRAM libérée va à l'IA.
- Deux écrans : Arma sur l'un, XERULITH sur l'autre.

Ollama Cloud

- Clé créée sur **ollama.com** → **Settings** → **Keys**, collée dans l'onglet IA (**Mémoriser** : chiffrée par Windows).
- Offres relevées le 20/10/2026 : **Free** 0 $ (modèles de départ, 1 requête à la fois) ; **Pro** 20 $/mois (3 requêtes simultanées, crédits mensuels) ; **Max** 100 $/mois (10 requêtes).
- Selon Ollama : requêtes et réponses **ni journalisées ni utilisées pour l'entraînement** ; serveurs surtout aux États-Unis, parfois en Europe.
- Un quota atteint est signalé en clair par XERULITH.

Quelle configuration choisir ?

Besoin	Conseil
Découvrir XERULITH et Arma 3 sur un PC de joueur	**Cloud minimale** (Free) ou **locale minimale** avec `gemma3:12b` seul
Formation régulière, plusieurs stagiaires	**Locale optimale** : un serveur Ollama de 24 Go pour la salle, un PC de simulation par stagiaire
Exercice sans Internet (coupure, terrain isolé)	**Locale** uniquement ; modèles téléchargés à l'avance
Données sensibles (images, positions)	**Locale** : rien ne sort du réseau
Comparer des modèles d'IA	**Locale optimale** + **cloud Pro** : mêmes missions, mêmes évaluations instructeur

Sources : configuration d'Arma 3 (arma3.com/requirements) ; tailles des modèles Ollama (ollama.com, catalogue des modèles) ; offres et confidentialité d'Ollama Cloud (ollama.com/pricing, ollama.com/search?c=cloud), consultés le 20 octobre 2026.